

Pre-Markingアクションを用いた Directed Controller Synthesisの 探索ヒューリスティック改善

大畑 允人
鄭研究室

発表の流れ

- 研究背景
- 従来手法：Ready Abstraction
- 提案手法：Landmark Ready Abstraction
- 評価
- 結論

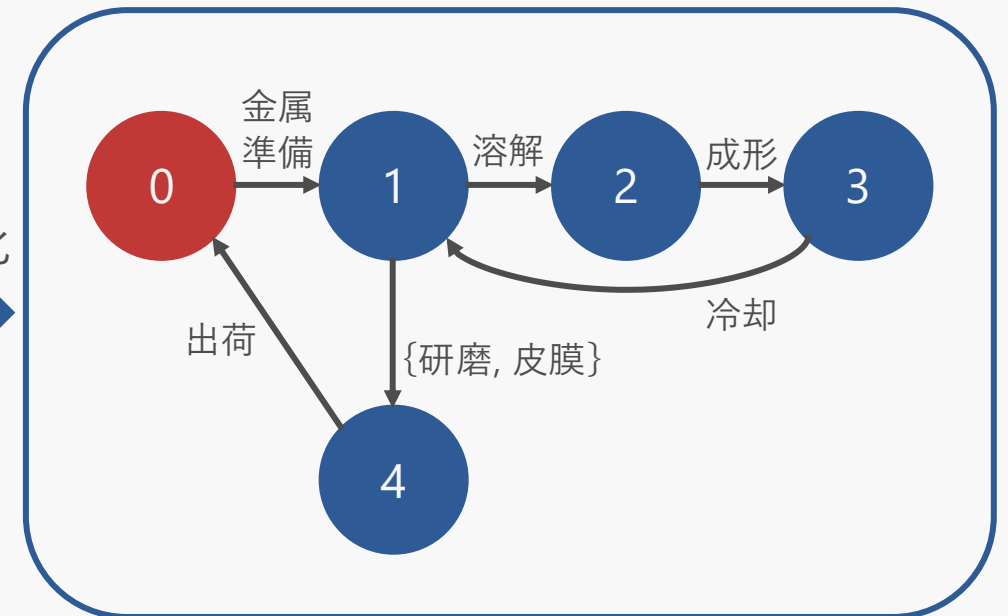
Discrete Event System (DES)¹

- アクションの発火により状態が離散的に遷移するシステム
- 状態遷移モデルで表現可能

金属加工
システム



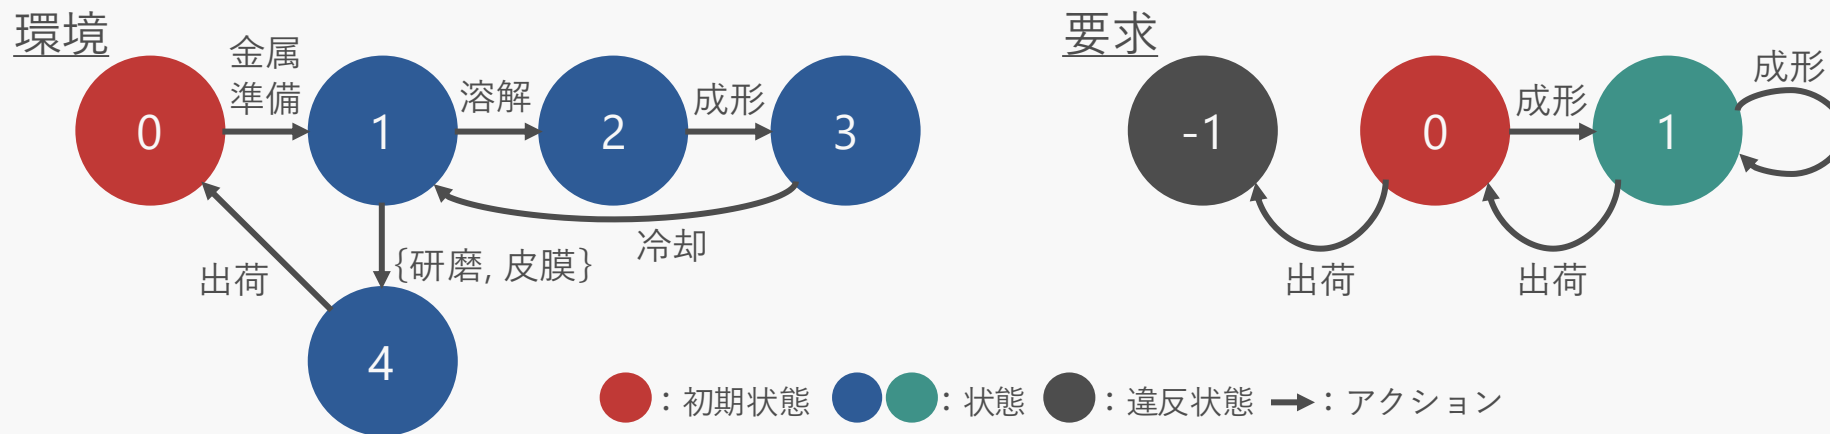
モデル化
→



1. P. J. Ramadge and W. M. Wonham. The control of discrete event systems. *Proceedings of the IEEE*, Vol. 77, No. 1, pp. 81–98, 1989.

Discrete Event Systemのモデル

- 環境モデル：システムの動作環境を表す
- 要求モデル：システムが充足しなければならない要求を表す



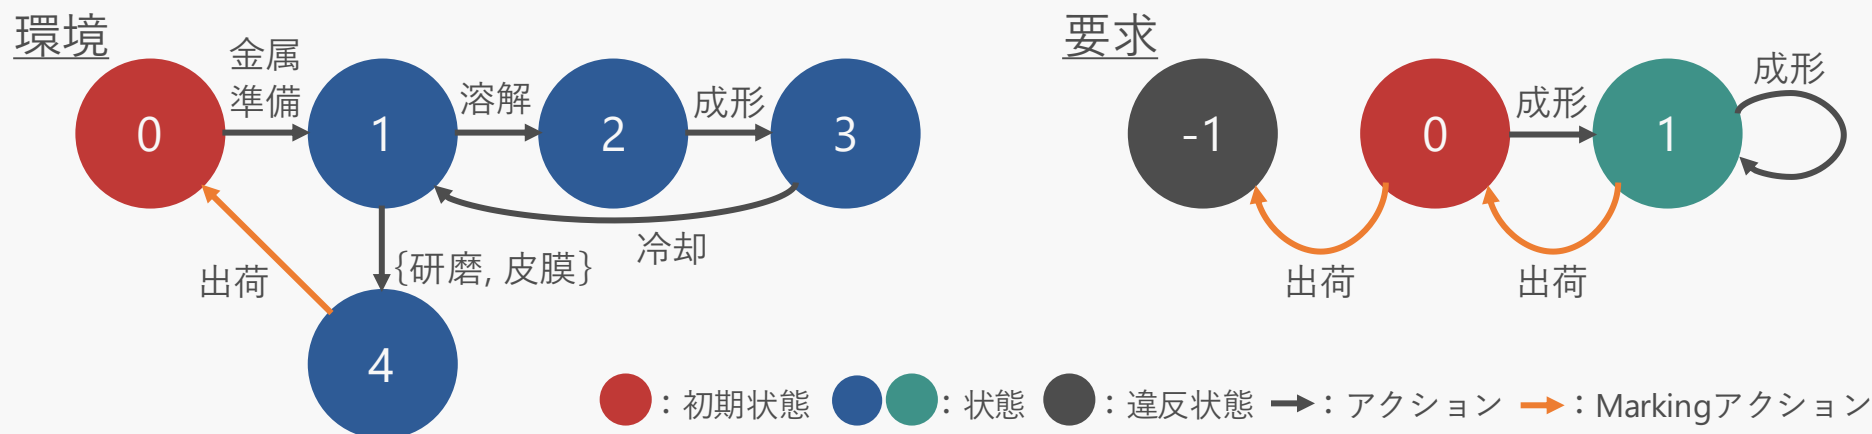
Discrete Event Systemのアクション

制御可能性

- Controllableアクション：システムが選択可能なアクション
- Uncontrollableアクション：システムが干渉できないアクション

目標

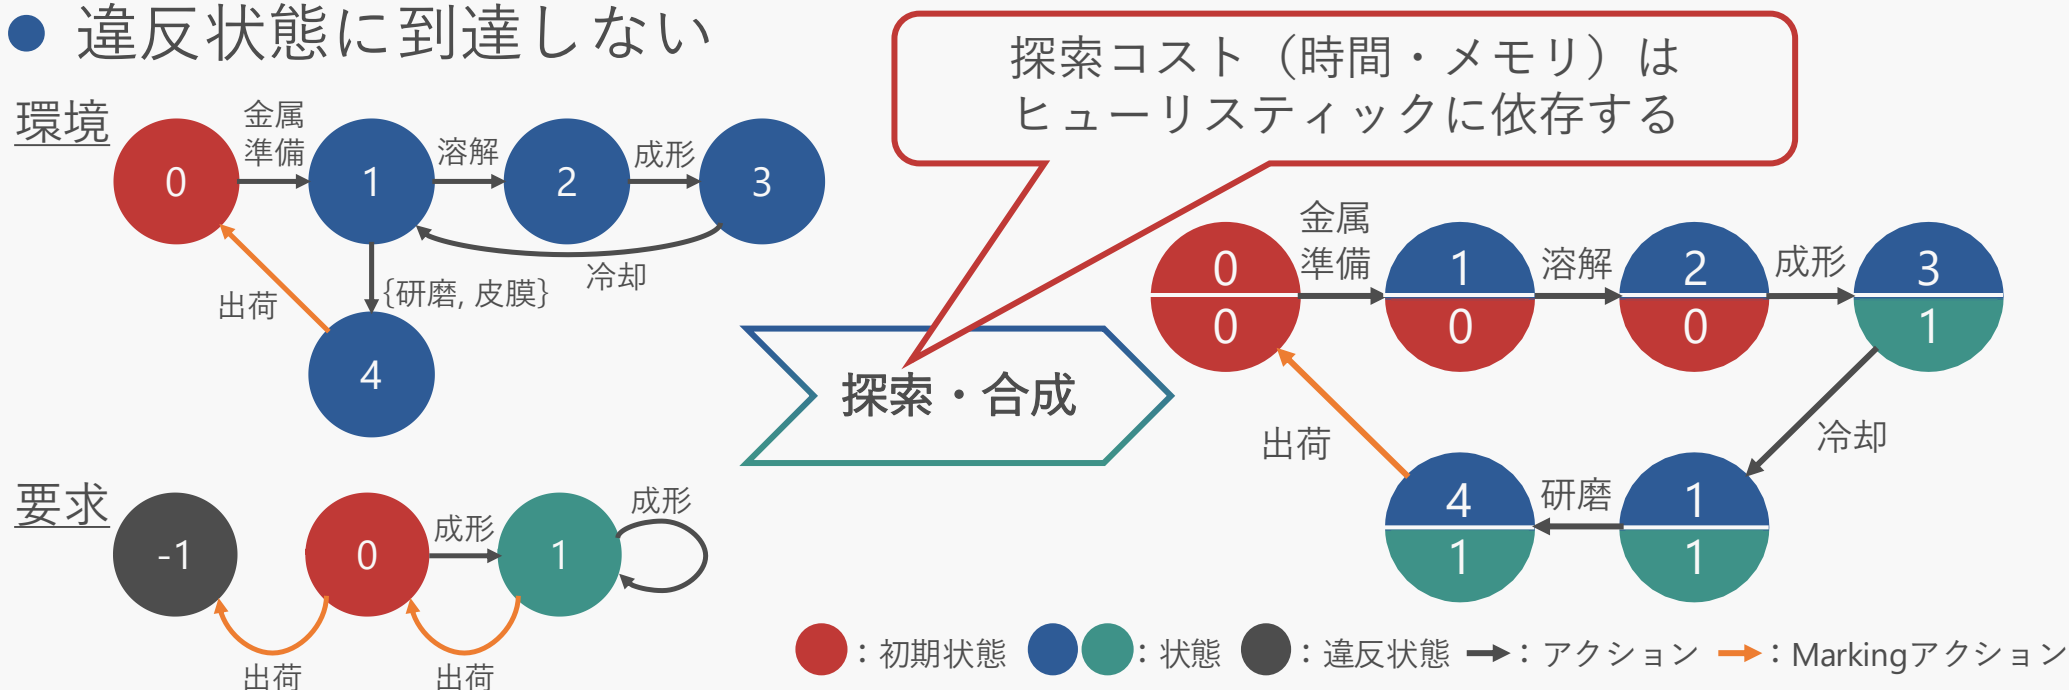
- Markingアクション：システムの達成したい目標アクション



Directed Controller Synthesis (DCS)¹

要求を満たす制御器を自動合成

- 初期状態からMarkingアクションの発火まで遷移
- 違反状態に到達しない



1. Daniel Ciolek, Víctor Braberman, Nicolás D'Ippolito, and Sebastián Uchitel. Directed controller synthesis of discrete event systems: Taming composition with heuristics. In 2016 IEEE 55th Conference on Decision and Control (CDC), pp. 4764–4769, 2016.

DCSのヒューリスティック

人手による設計

長所

- 事前学習が不要
- 計算の根拠が明確

短所

- 複雑な同期構造など、設計者が想定していない構造に弱い

強化学習による獲得¹

長所

- 同一構造で規模が異なる問題に対して高い汎用性を持つ

短所

- 構造が変化すると適用できない（再学習が必要）
- 学習用モデルを作成する必要がある

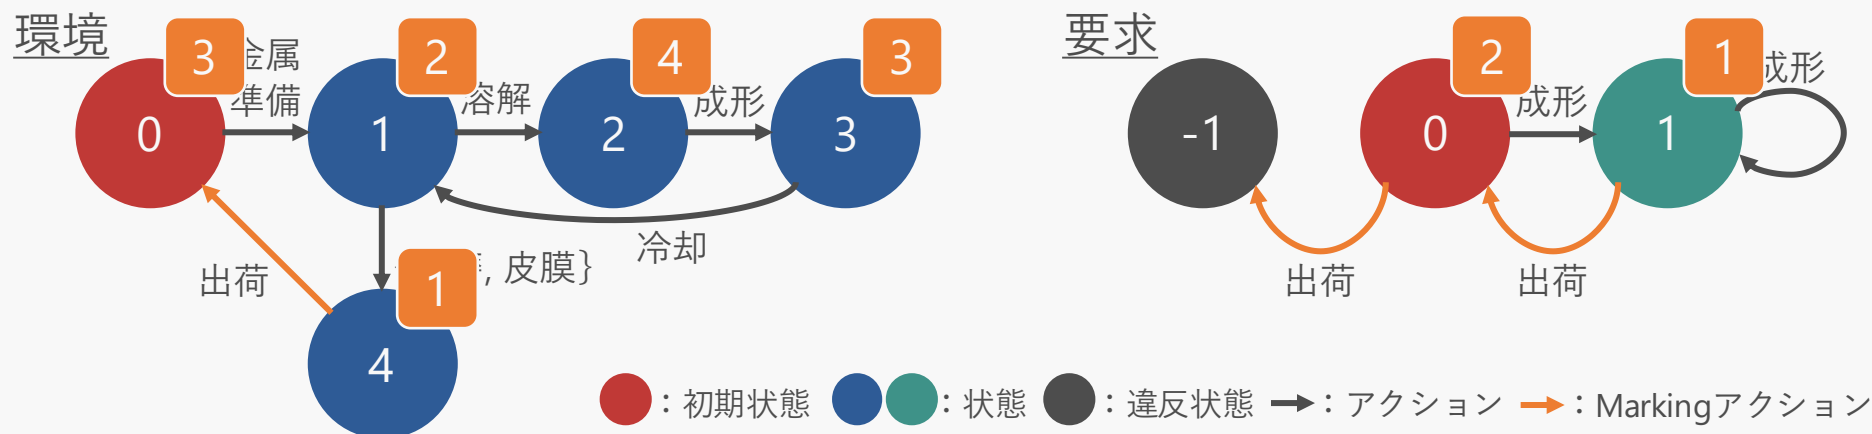
➡ 汎用性の高い「人手による設計」に焦点を当て、その探索効率を改善する

1. Tomas Delgado, Marco Sánchez Sorondo, Víctor Braberman, and Sebastián Uchitel. Exploration policies for on-the-fly controller synthesis: a reinforcement learning approach. In *Proceedings of the Thirty-Third International Conference on Automated Planning and Scheduling, ICAPS '23*. AAAI Press, 2023.

Ready Abstraction (RA)¹

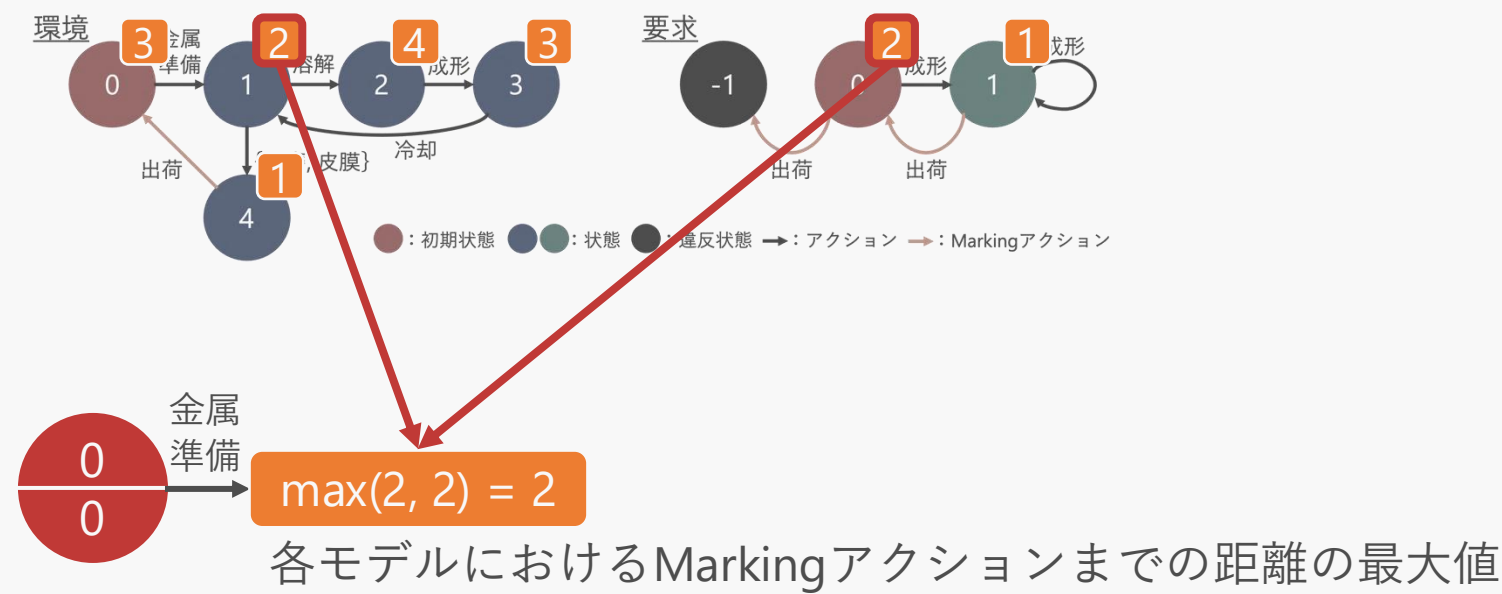
Directed Controller Synthesisの探索ヒューリスティック

1. 入力モデルのすべての状態について、Markingアクションを発火するのに必要な遷移数を計算
2. 複数のモデルを比較し、最もMarkingアクションに近づくアクションを優先して探索

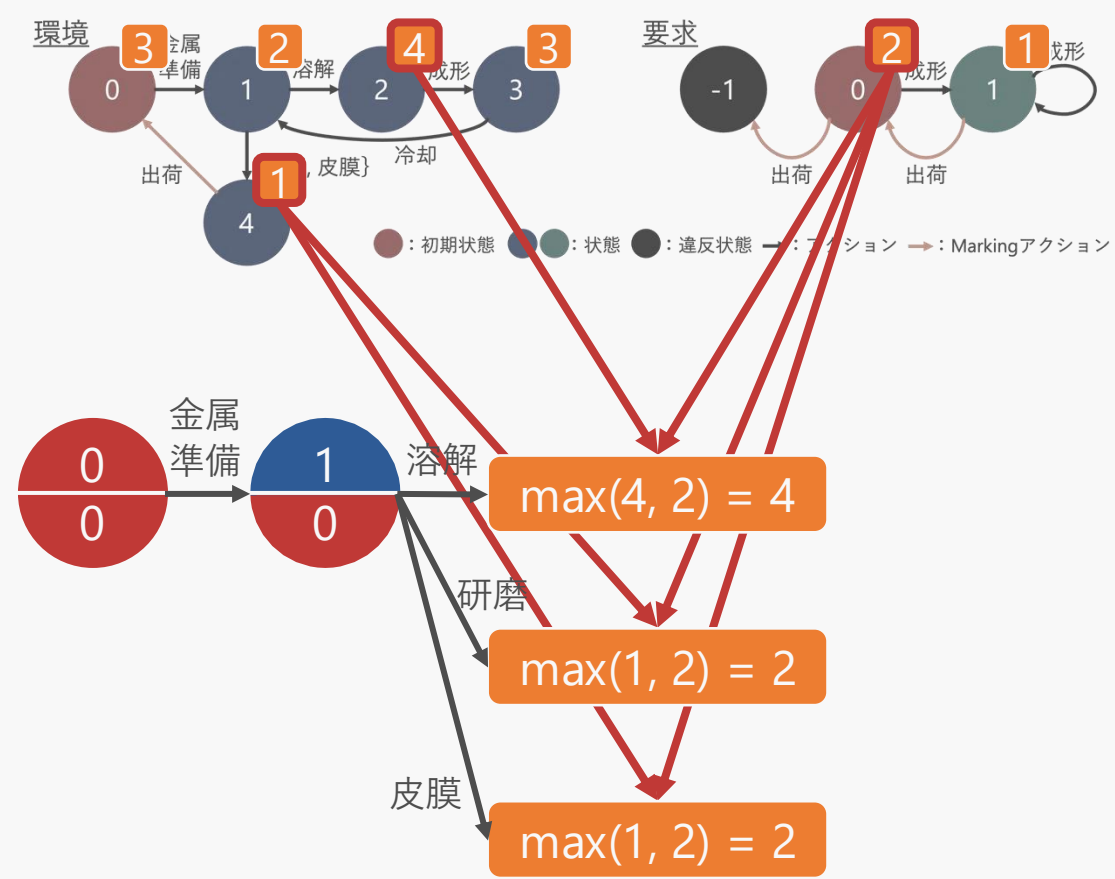


1. Daniel Ciolek, Matias Duran, Florencia Zanollo, Nicolas Pazos, Julián Braier, Víctor Braberman, Nicolás D'Ippolito, and Sebastián Uchitel. On-the-fly informed search of non-blocking directed controllers. *Automatica*, Vol. 147, No. C, January 2023.

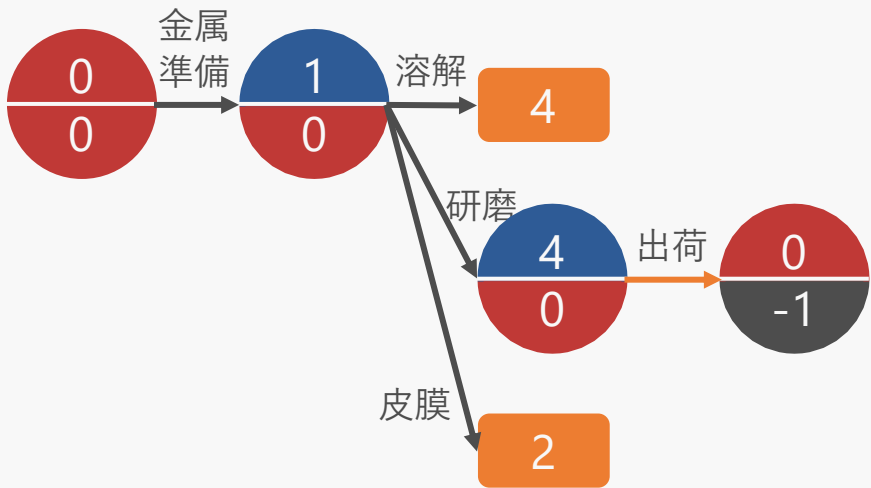
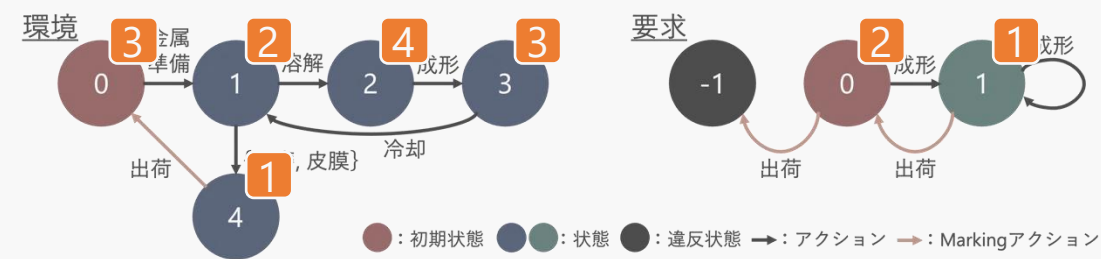
Ready Abstraction (RA) による探索



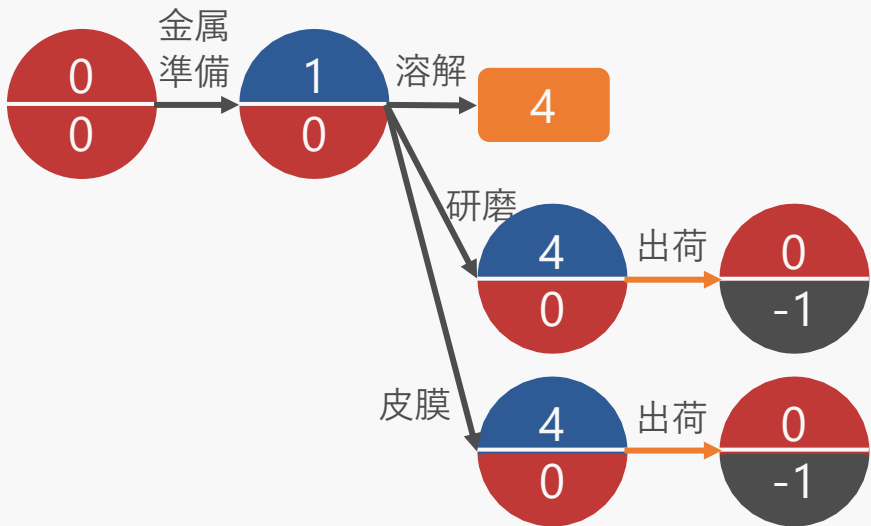
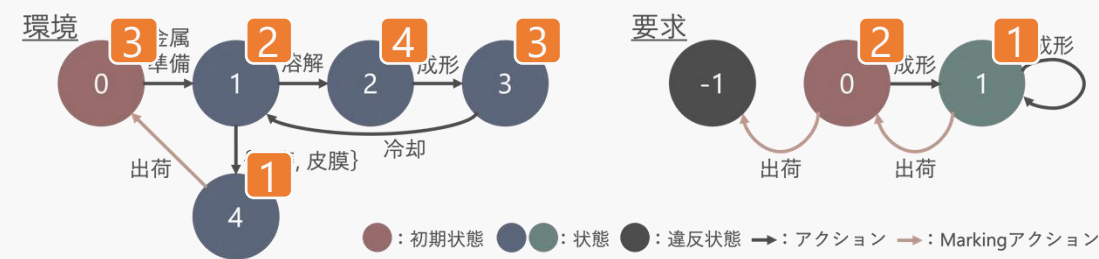
Ready Abstraction (RA) による探索



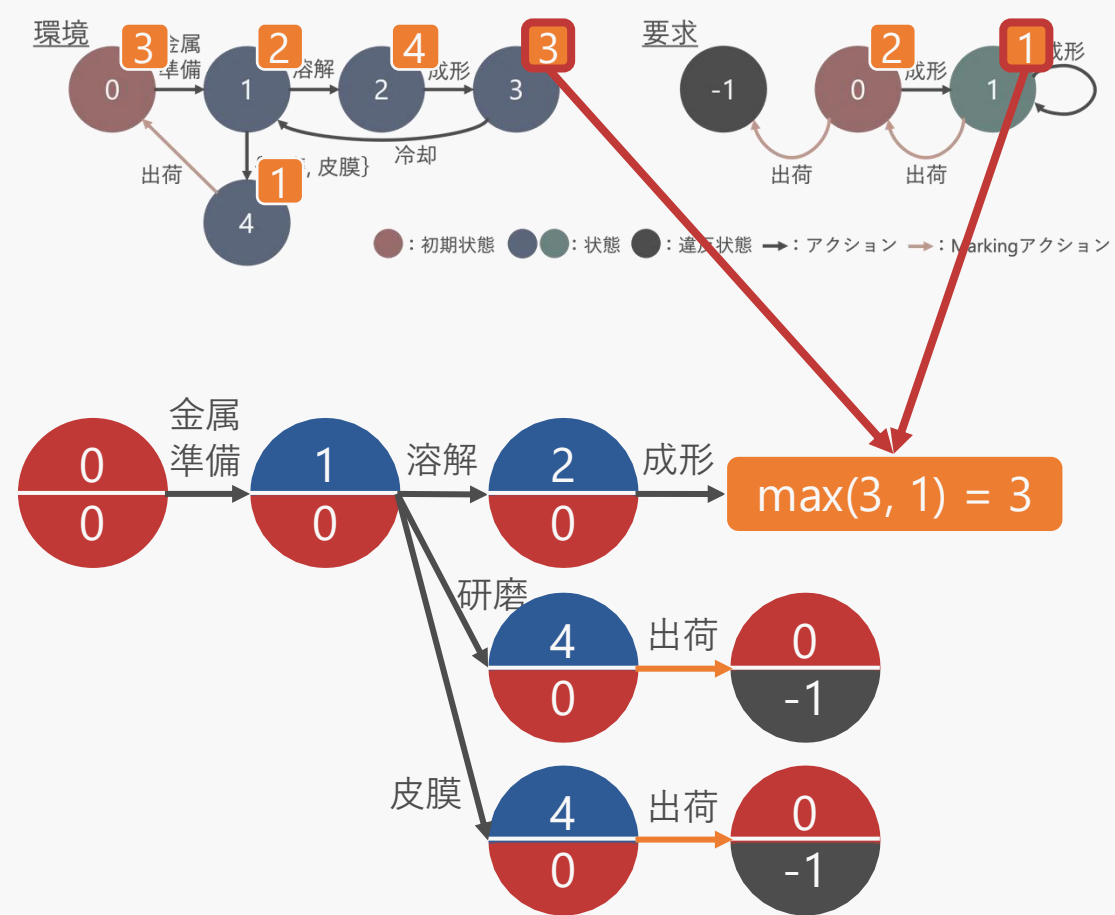
Ready Abstraction (RA) による探索



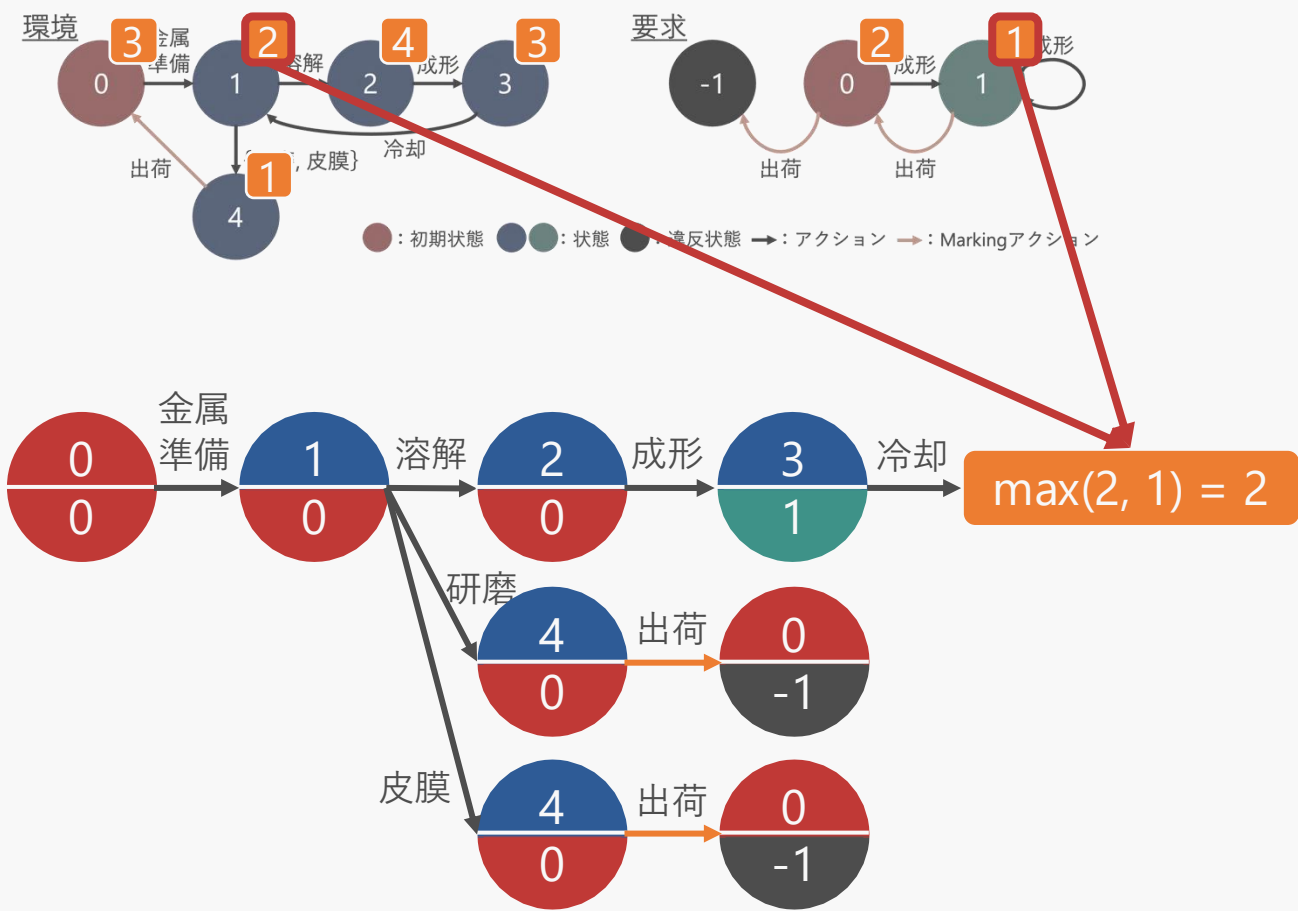
Ready Abstraction (RA) による探索



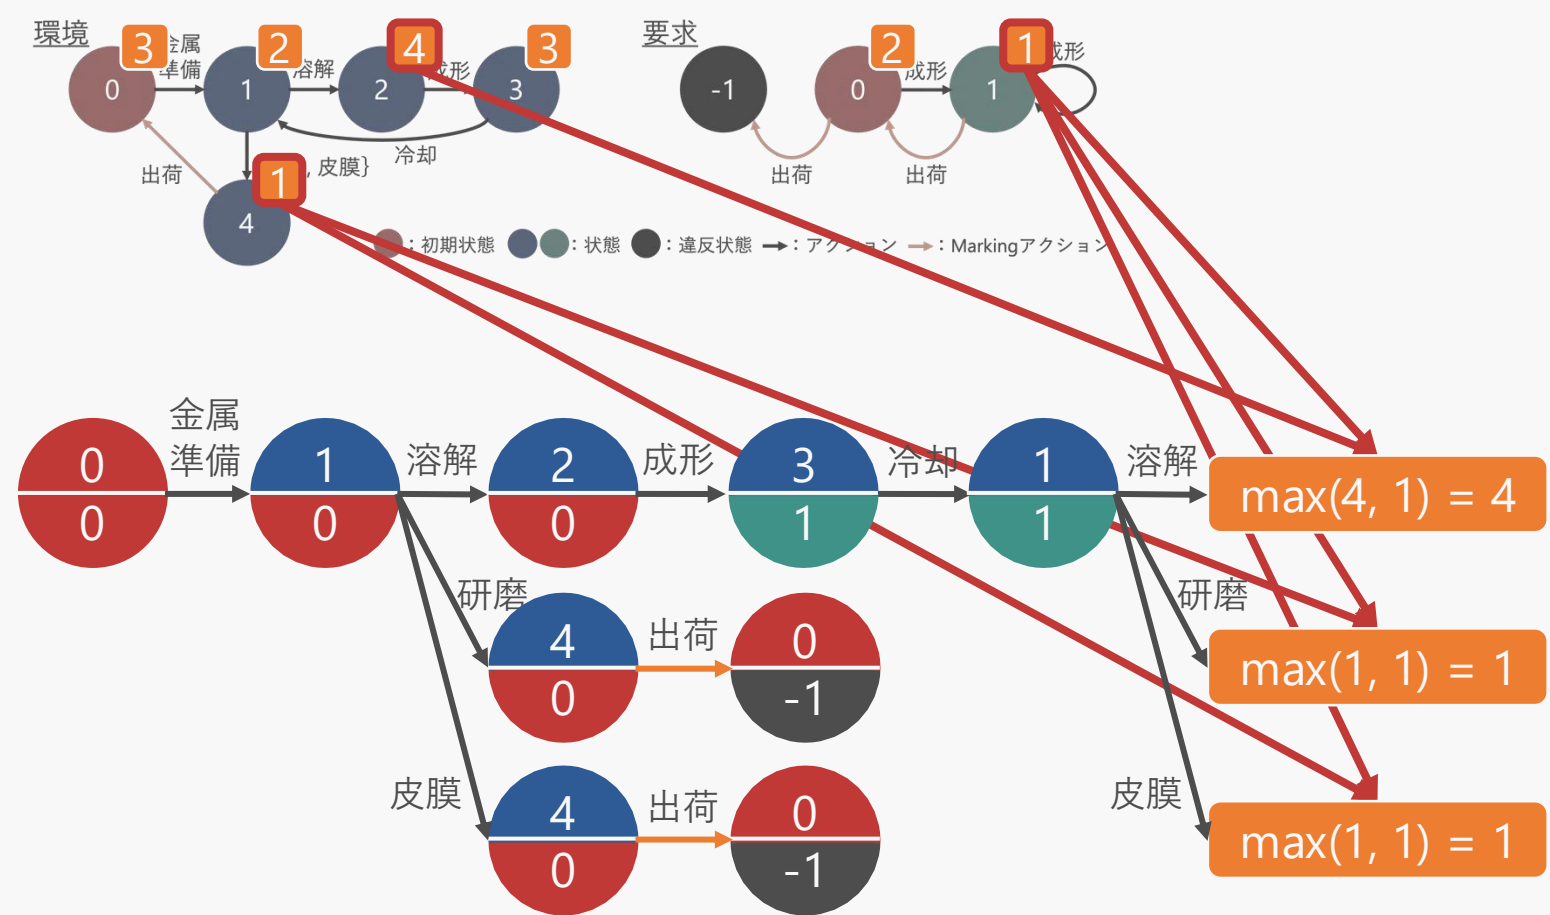
Ready Abstraction (RA) による探索



Ready Abstraction (RA) による探索



Ready Abstraction (RA) による探索



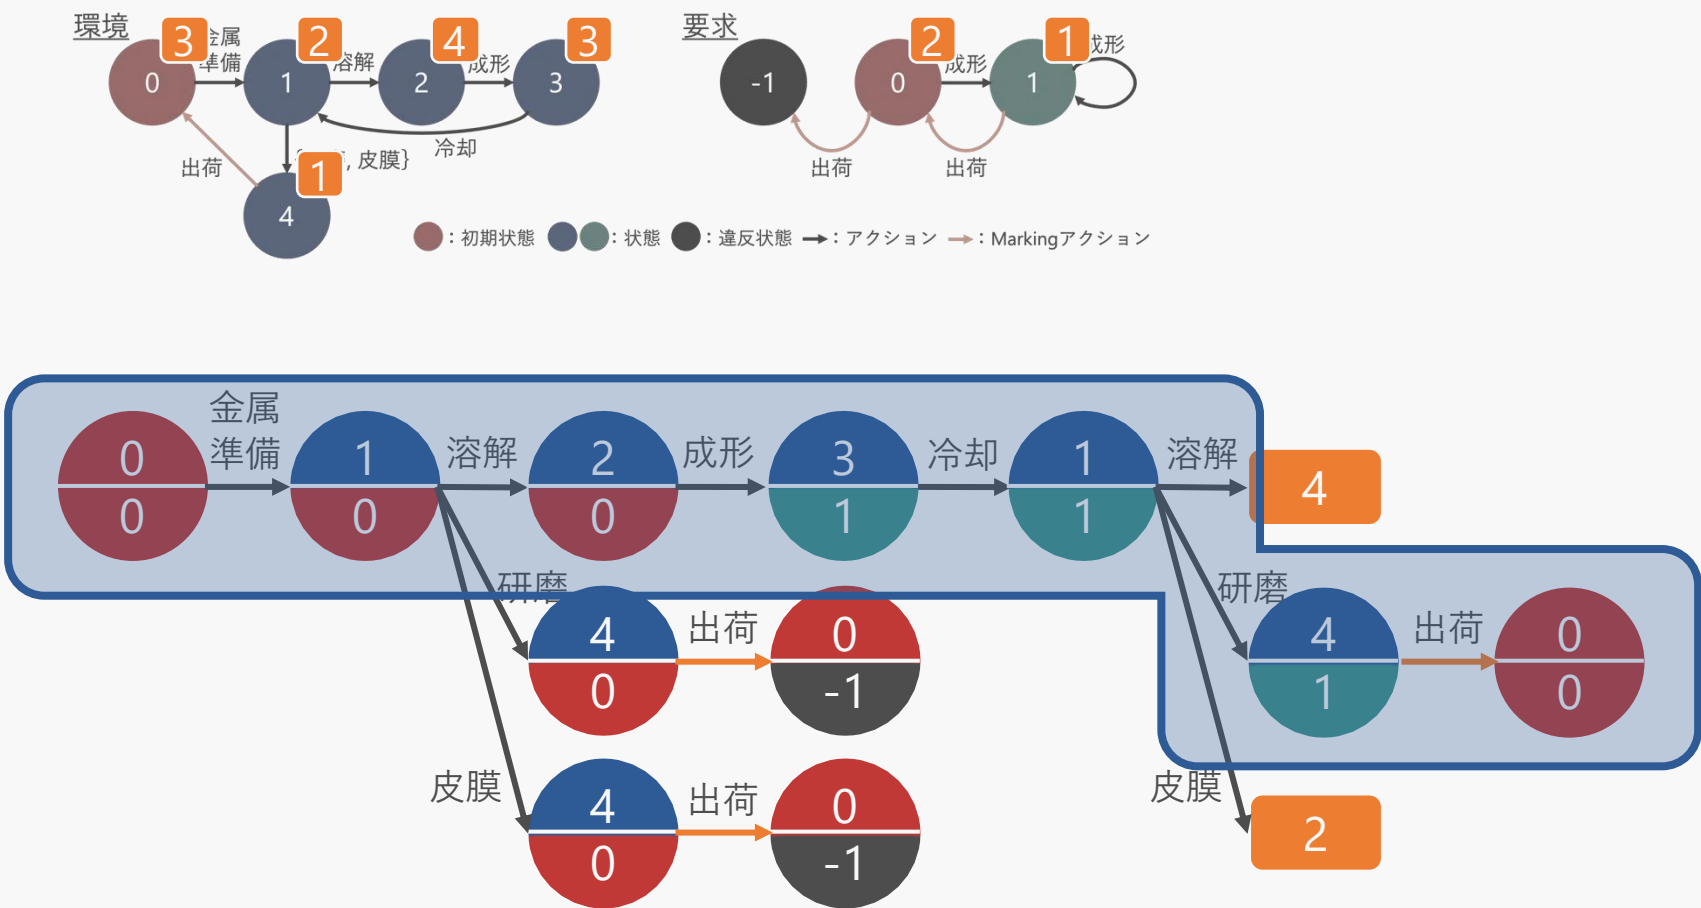
環境

要求

● : 初期状態 ● : 状態 ● : 違反状態 → : アクション → : Markingアクション



Ready Abstraction (RA) による探索



Ready Abstraction (RA) の探索特性と静的RA

Uncontrollableアクションへの対応

- Markingアクション発火後も探索を継続し、環境の全振る舞いを網羅する

RAの探索特性

- 探索空間の抑制に向け、探索履歴を参照して既知のMarkingアクションへの到達を優先する

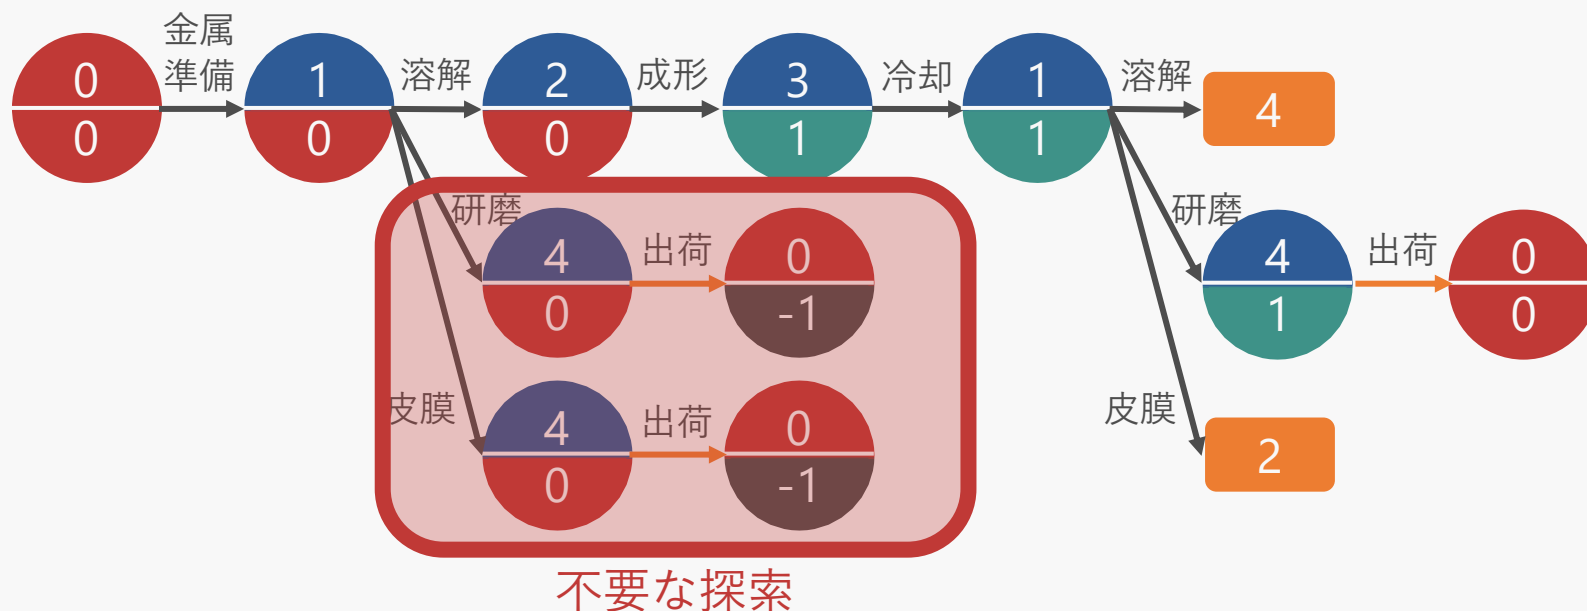
静的RA (Static Ready Abstraction, SRA) の定義

- 履歴利用の効果を検証するため、静的構造のみを用いる手法として定義する

Ready Abstraction (RA) の問題点

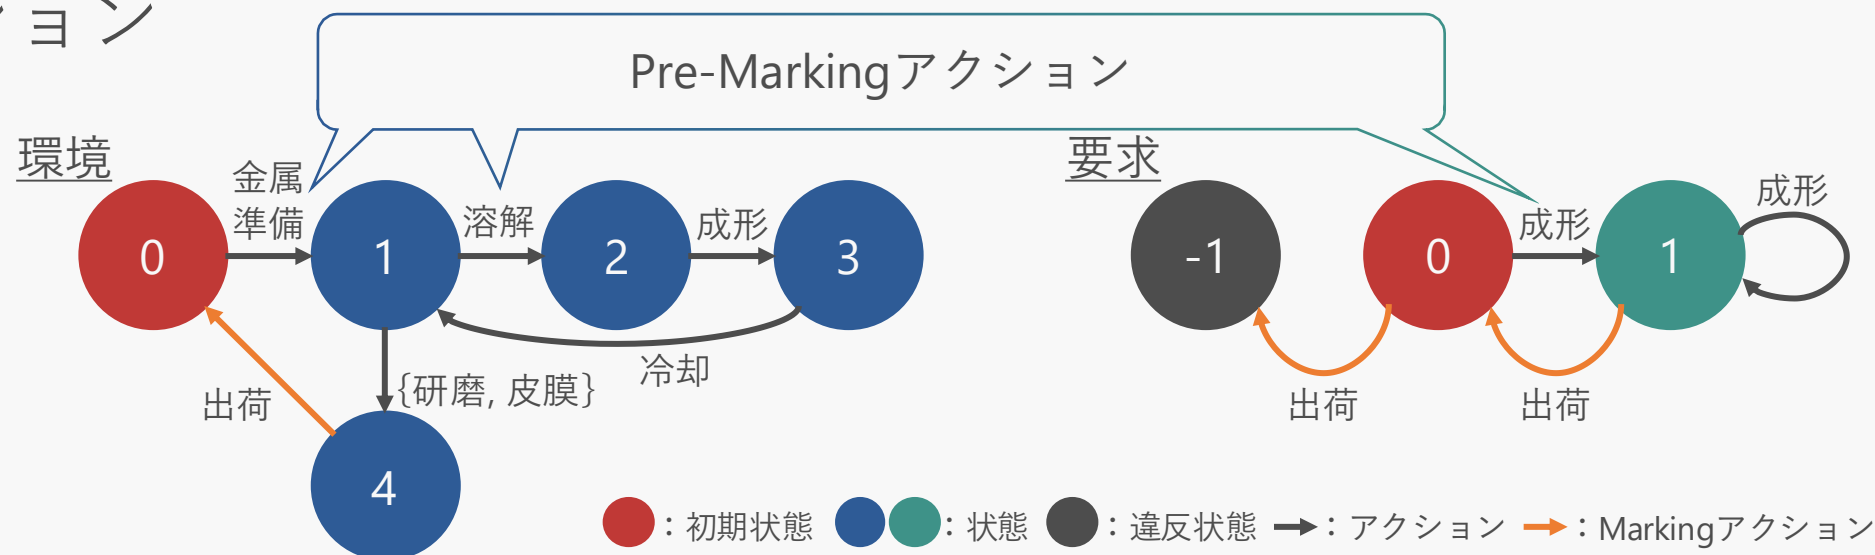
同期不足により、目先のMarkingアクションへ不要な探索

Markingアクションの前に中間目標を設定して解決



Landmark Ready Abstraction (LRA)

- Pre-Markingアクションを中間目標（ランドマーク）として探索
- Pre-Markingアクション：
初期状態からMarkingアクションの発火までに必ず発火するアクション



Landmark Ready Abstraction (LRA) の全体像

1. 事前分析

モデルの構造を静的に解析し、目標達成に不可欠なボトルネック（Pre-Markingアクション）を特定する

2. 探索

特定したPre-Markingアクションを中間目標（ランドマーク）として利用し、効率的なヒューリスティック探索を行う

Landmark Ready Abstraction (LRA) の全体像

1. 事前分析

モデルの構造を静的に解析し、目標達成に不可欠なボトルネック（Pre-Markingアクション）を特定する

2. 探索

特定したPre-Markingアクションを中間目標（ランドマーク）として利用し、効率的なヒューリスティック探索を行う

Pre-Markingアクション (PMA)

Markingアクションを起点とする依存関係により再帰的に定義

- **Primary Pre-Markingアクション (PPMA)**
Markingアクションの発火に直接必須なアクション
- **Secondary Pre-Markingアクション (SPMA)**
PPMAや他のSPMAの発火に必須なアクション



Pre-Markingアクション（PMA）の特定

1. モデルの選定

目標のアクションを含むモデルを抽出する

2. 候補の絞り込み

初期状態から目標までの最短パスを導出し、PMAの候補とする

3. 必須性の検証と状態への割り当て

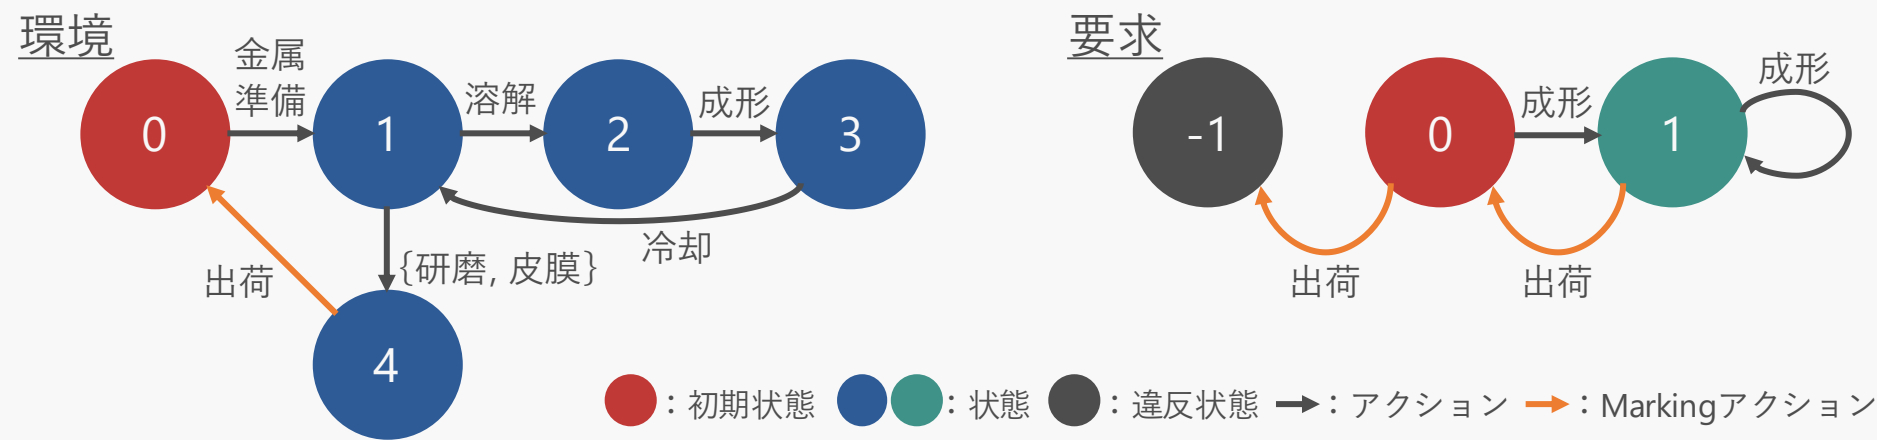
候補のアクションを除くと初期状態から目標までのパスがなくなる場合、PMAと確定する

同時に、目標までのパスがなくなった全ての状態に、そのPMAを中間目標として登録する

Primary Pre-Markingアクション (PPMA) の特定

1. モデルの選定

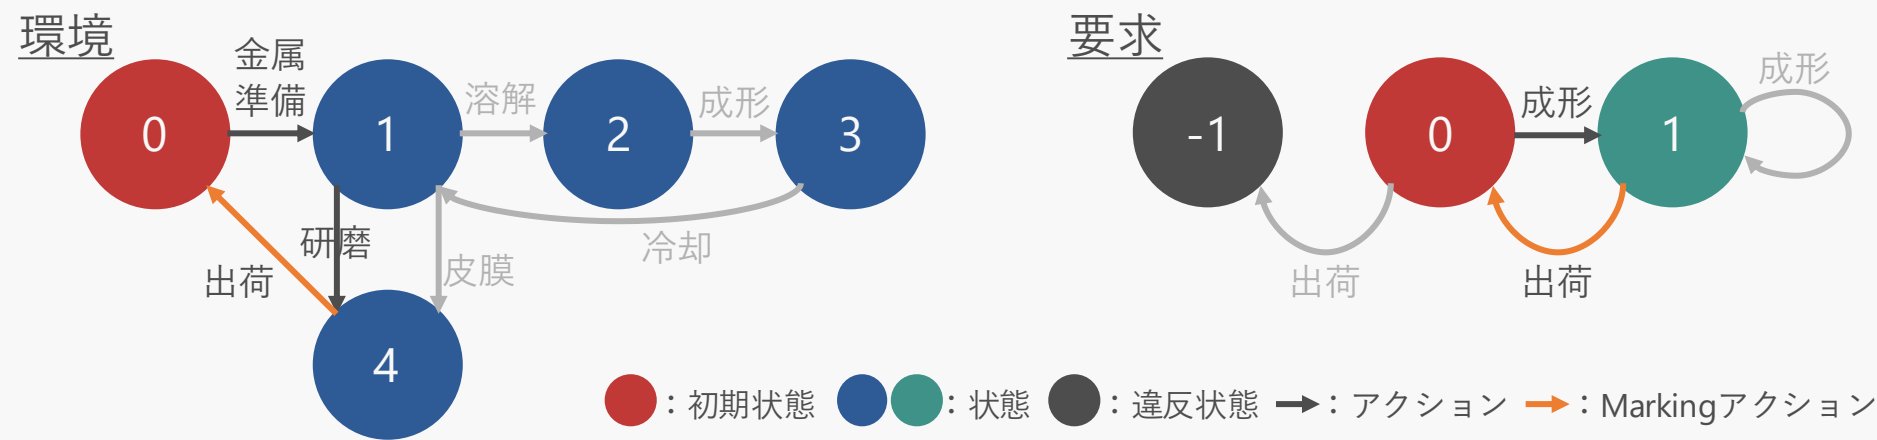
目標のアクション（= Markingアクション）を含むモデルを抽出する



Primary Pre-Markingアクション (PPMA) の特定

2. 候補の絞り込み

初期状態からMarkingアクションまでの最短パスを導出し、PPMAの候補とする

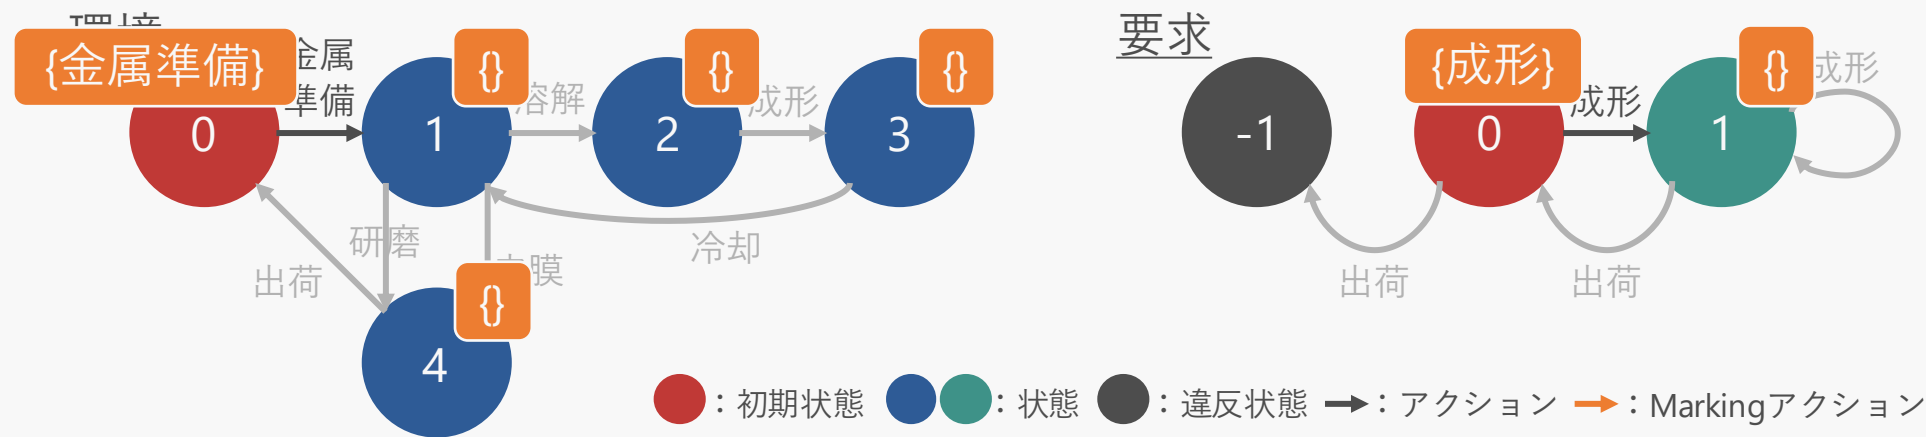


Primary Pre-Markingアクション (PPMA) の特定

3. 必須性の検証と状態への割り当て

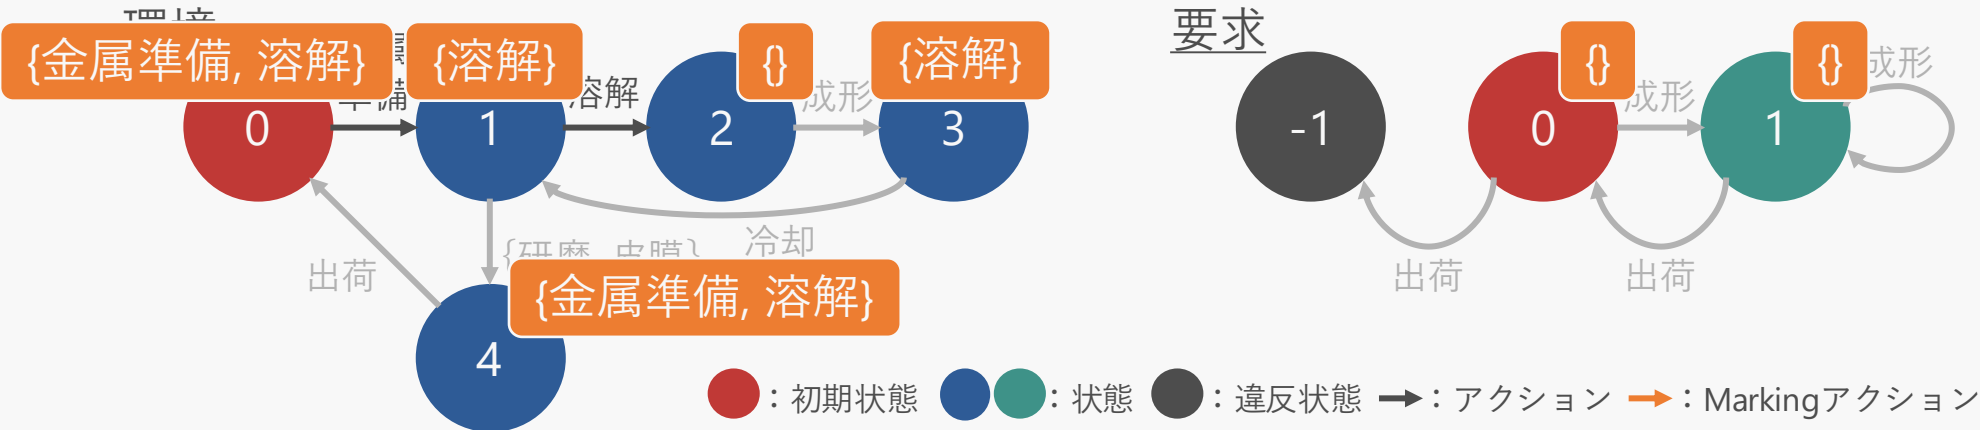
候補のアクションを除くと初期状態からMarkingアクションまでのパスがなくなる場合、PPMAと確定する

同時に、Markingアクションまでのパスがなくなった全ての状態に、そのPPMAを中間目標として登録する



Secondary Pre-Markingアクションの特定

Primary Pre-Markingアクション「成形」に対する
未発火のSecondary Pre-Markingアクションの割り当て



Landmark Ready Abstraction (LRA) の全体像

1. 事前分析

モデルの構造を静的に解析し、目標達成に不可欠なボトルネック（Pre-Markingアクション）を特定する

2. 探索

特定したPre-Markingアクションを中間目標（ランドマーク）として利用し、効率的なヒューリスティック探索を行う

Pre-Markingアクション（PMA）を用いた距離推定

2通りの距離の過小評価の最大値

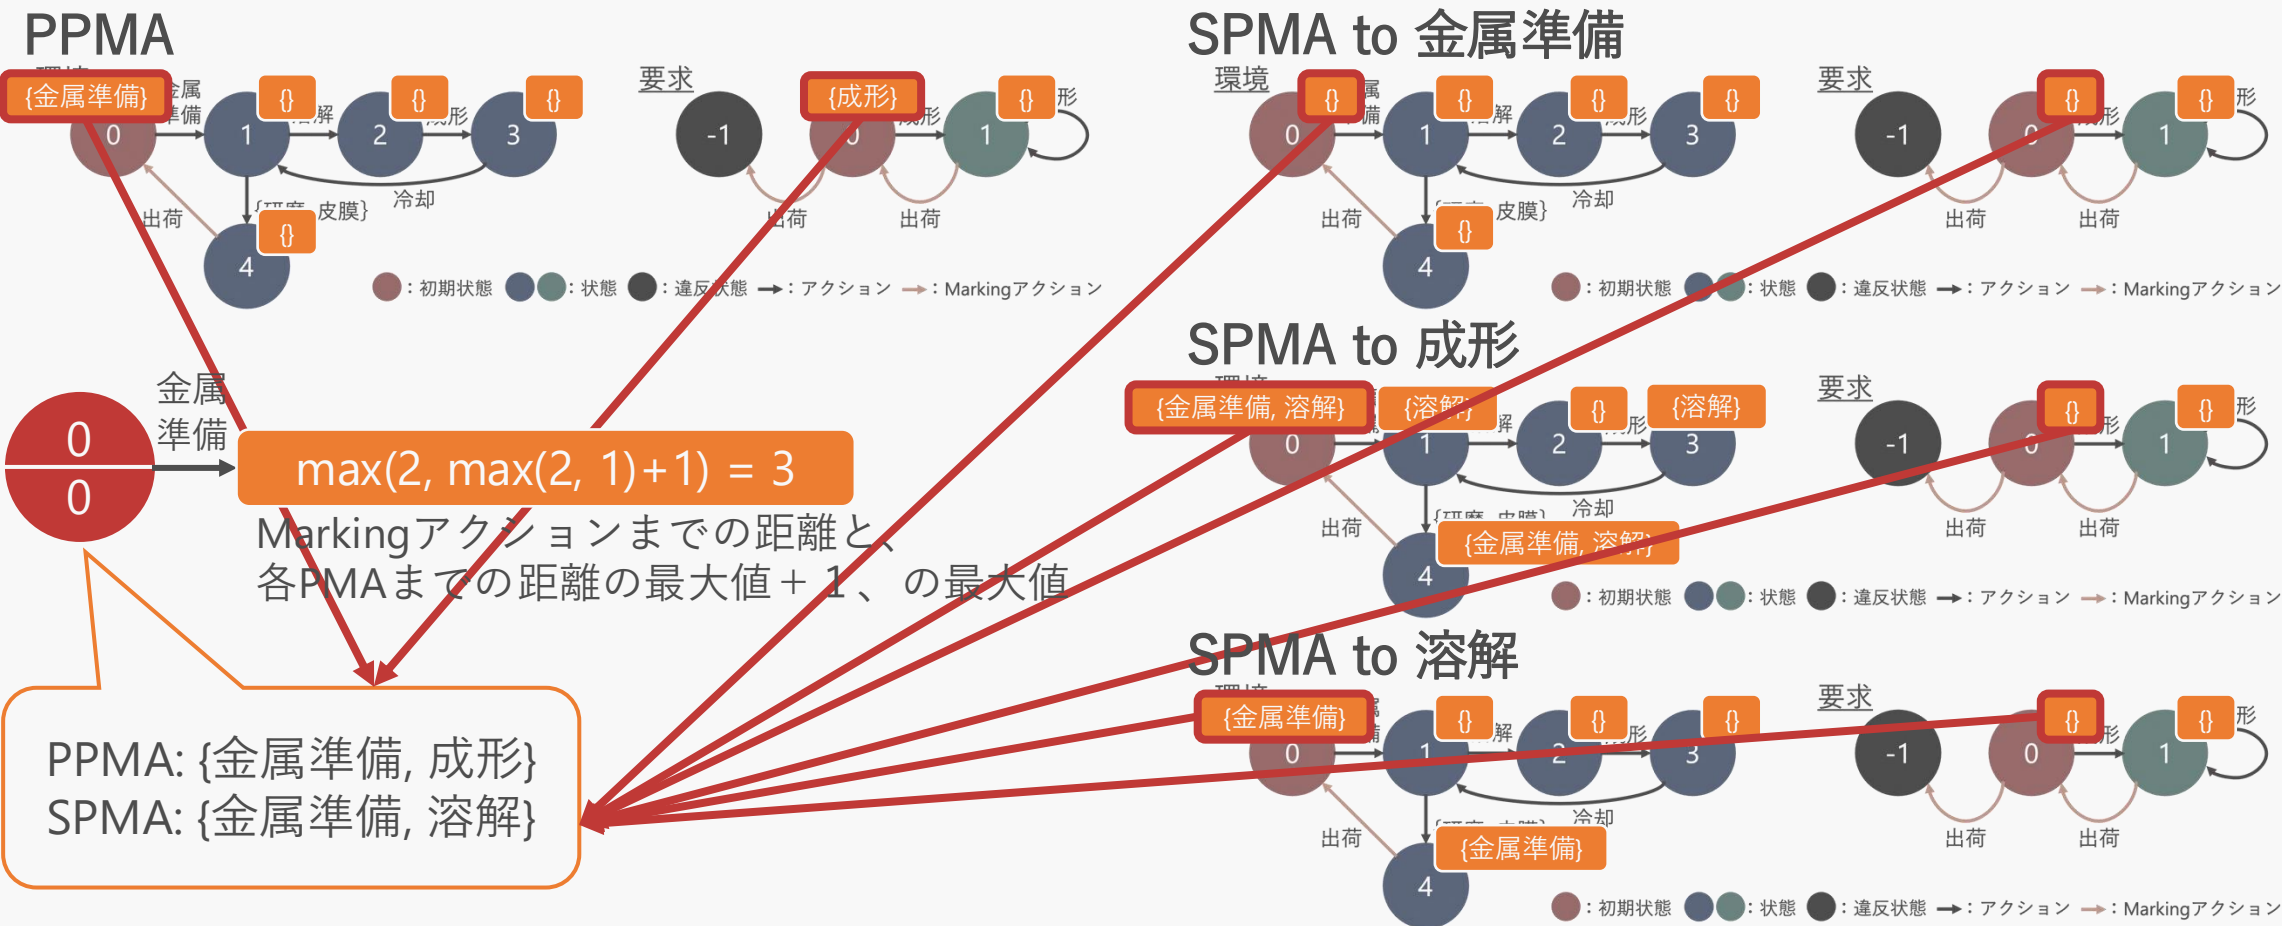
- **Markingアクションまでの距離**

SRAによる推定距離と同じ値

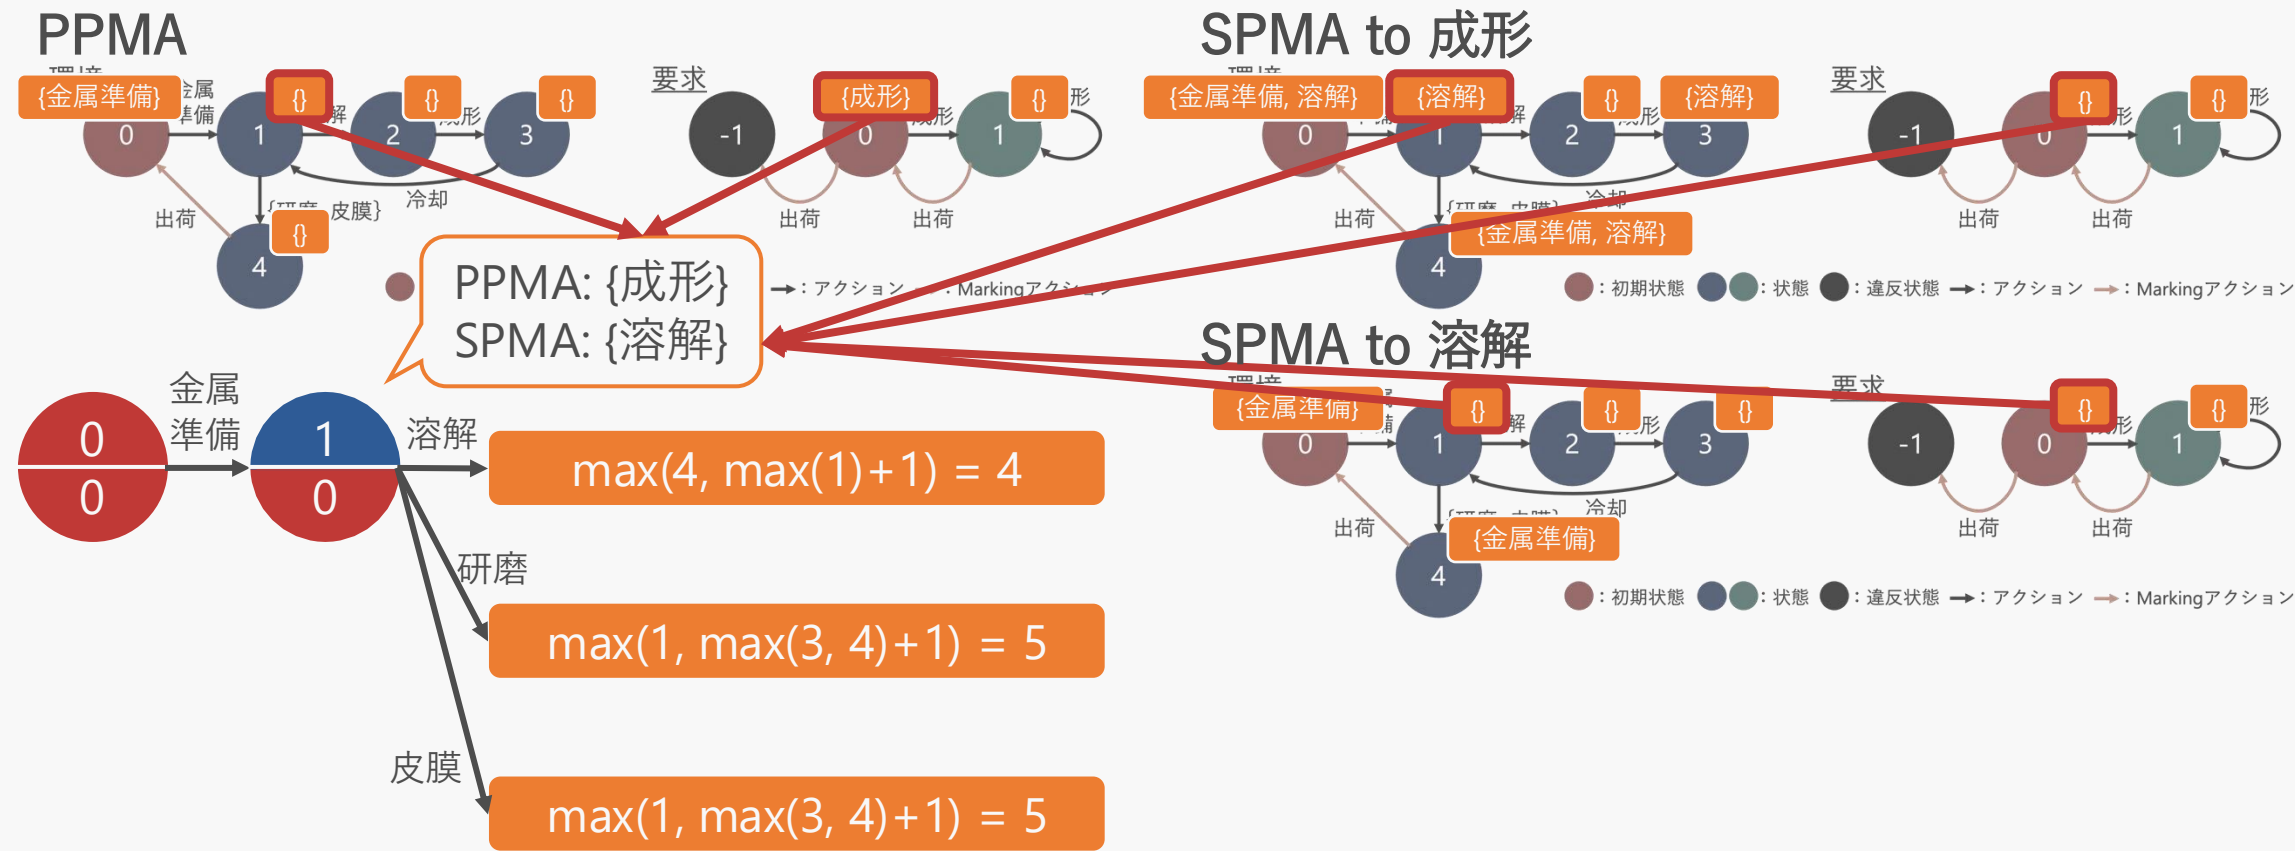
- **最も遠いPre-Markingアクションまでの距離 + 1**

ボトルネックを解消後、すぐにMarkingアクションが発火できる場合

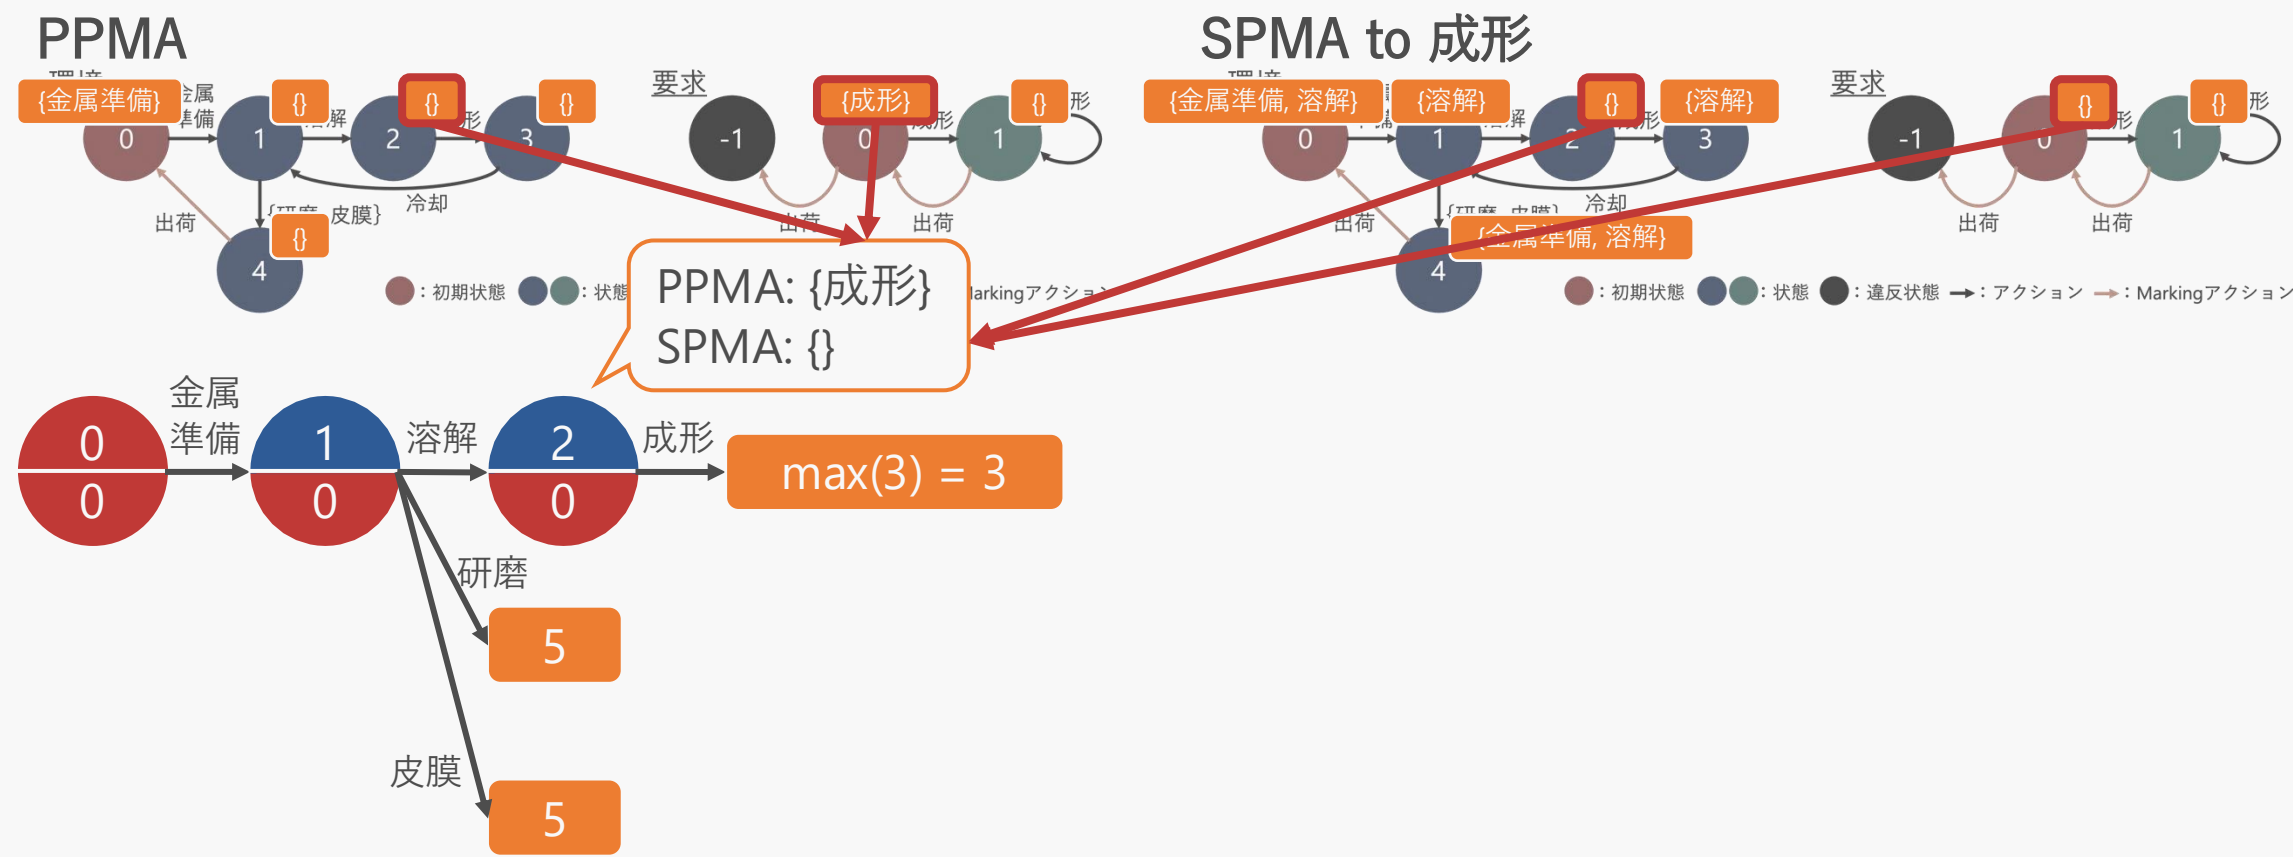
Landmark Ready Abstraction (LRA) による探索



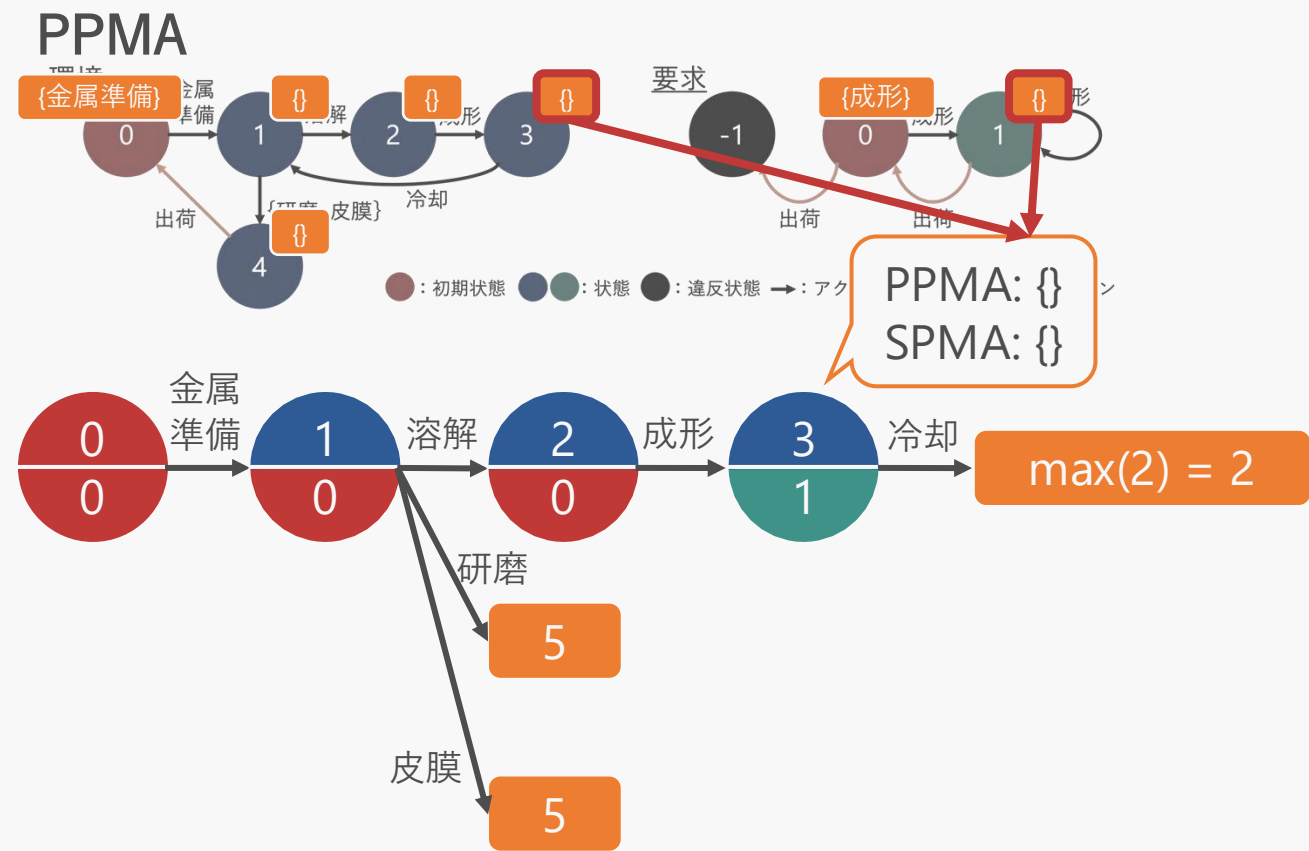
Landmark Ready Abstraction (LRA) による探索



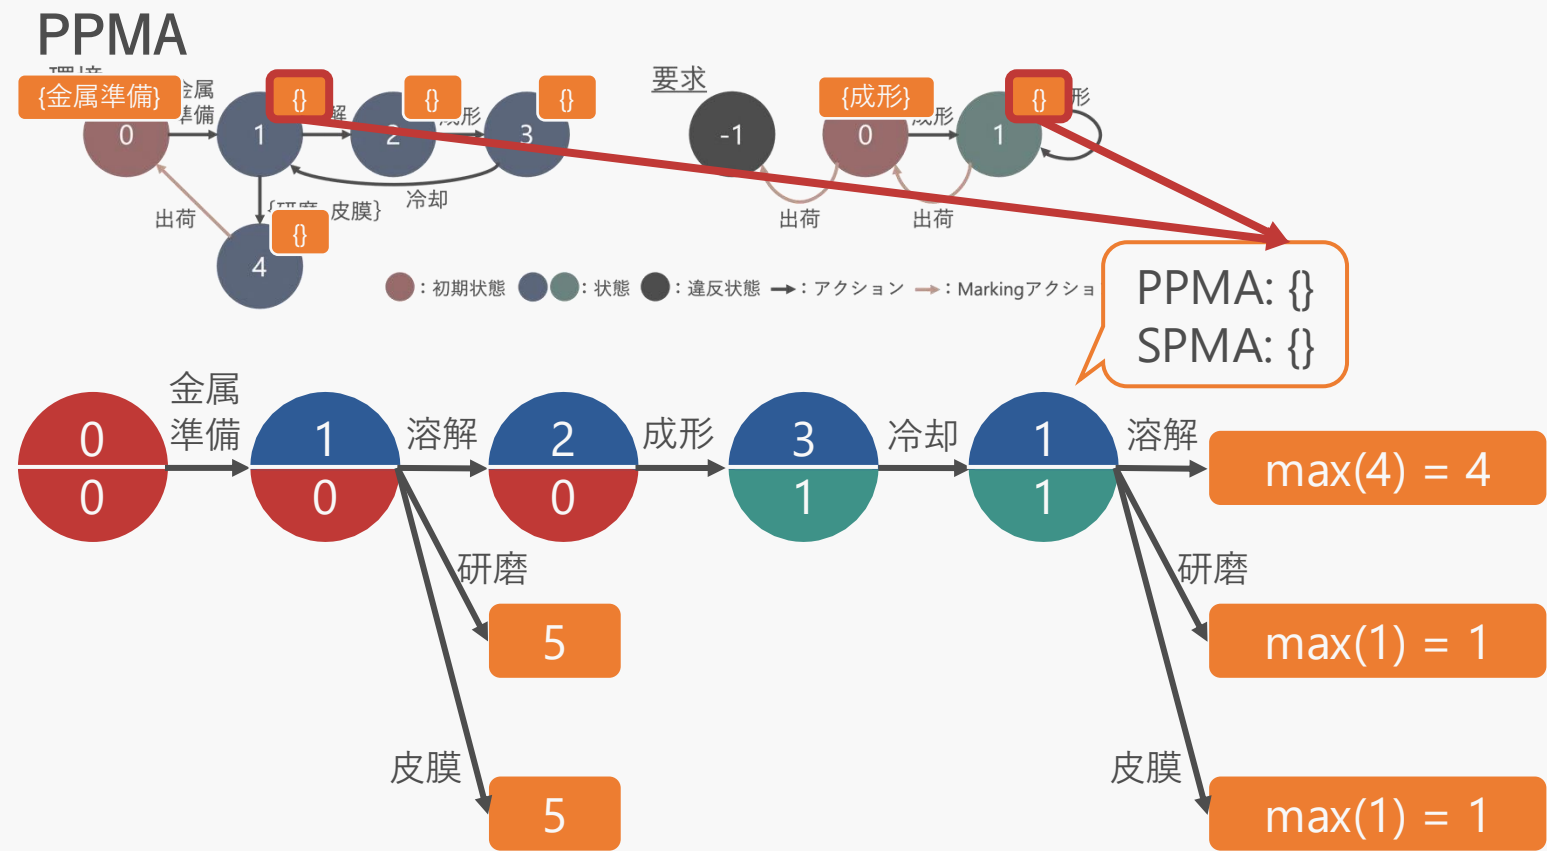
Landmark Ready Abstraction (LRA) による探索



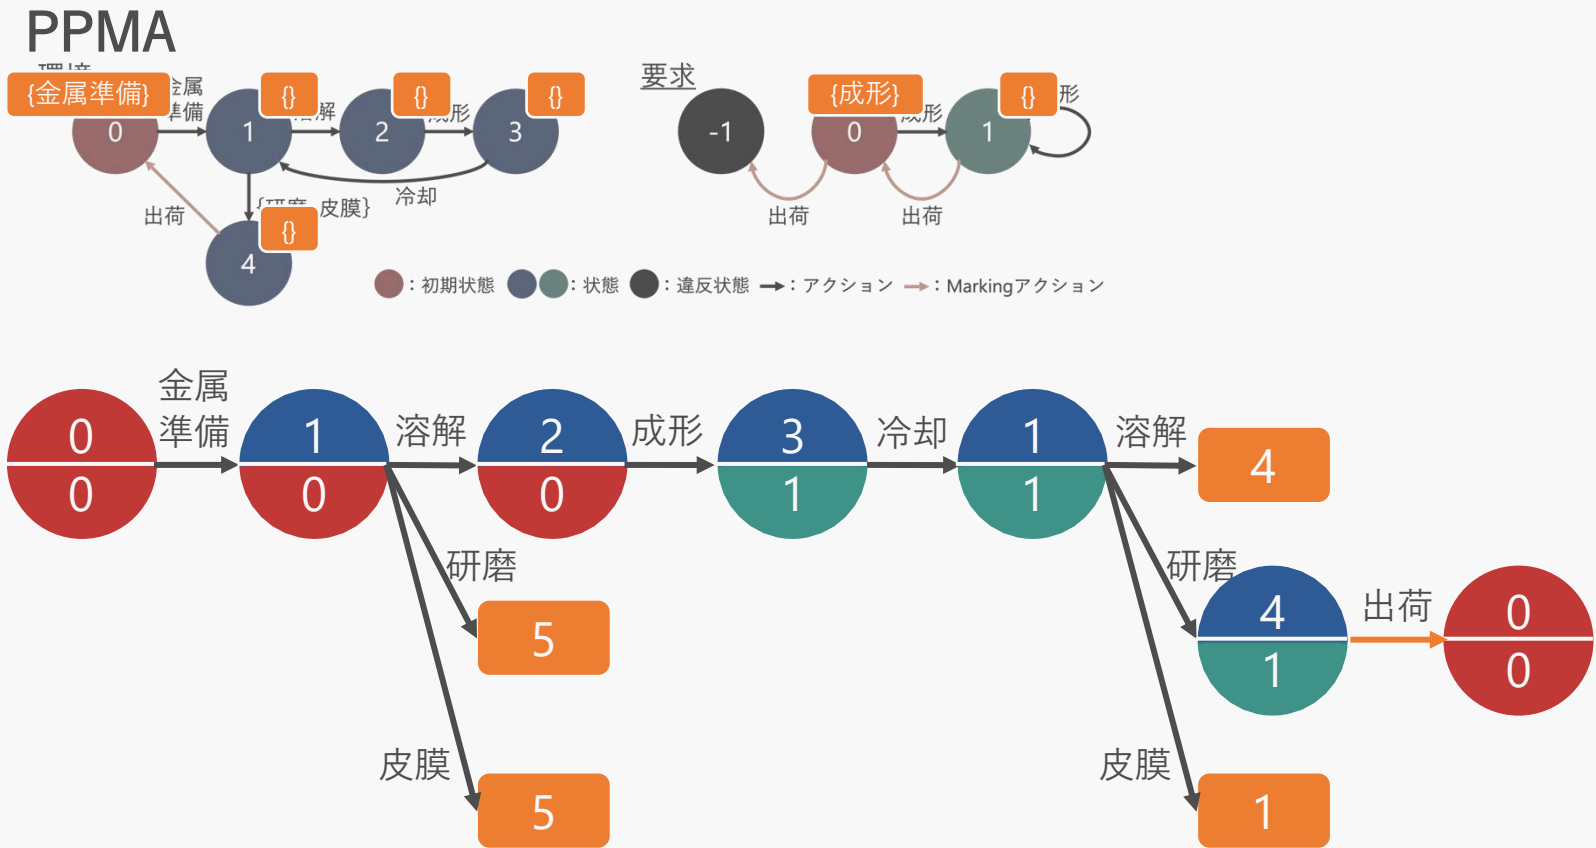
Landmark Ready Abstraction (LRA) による探索



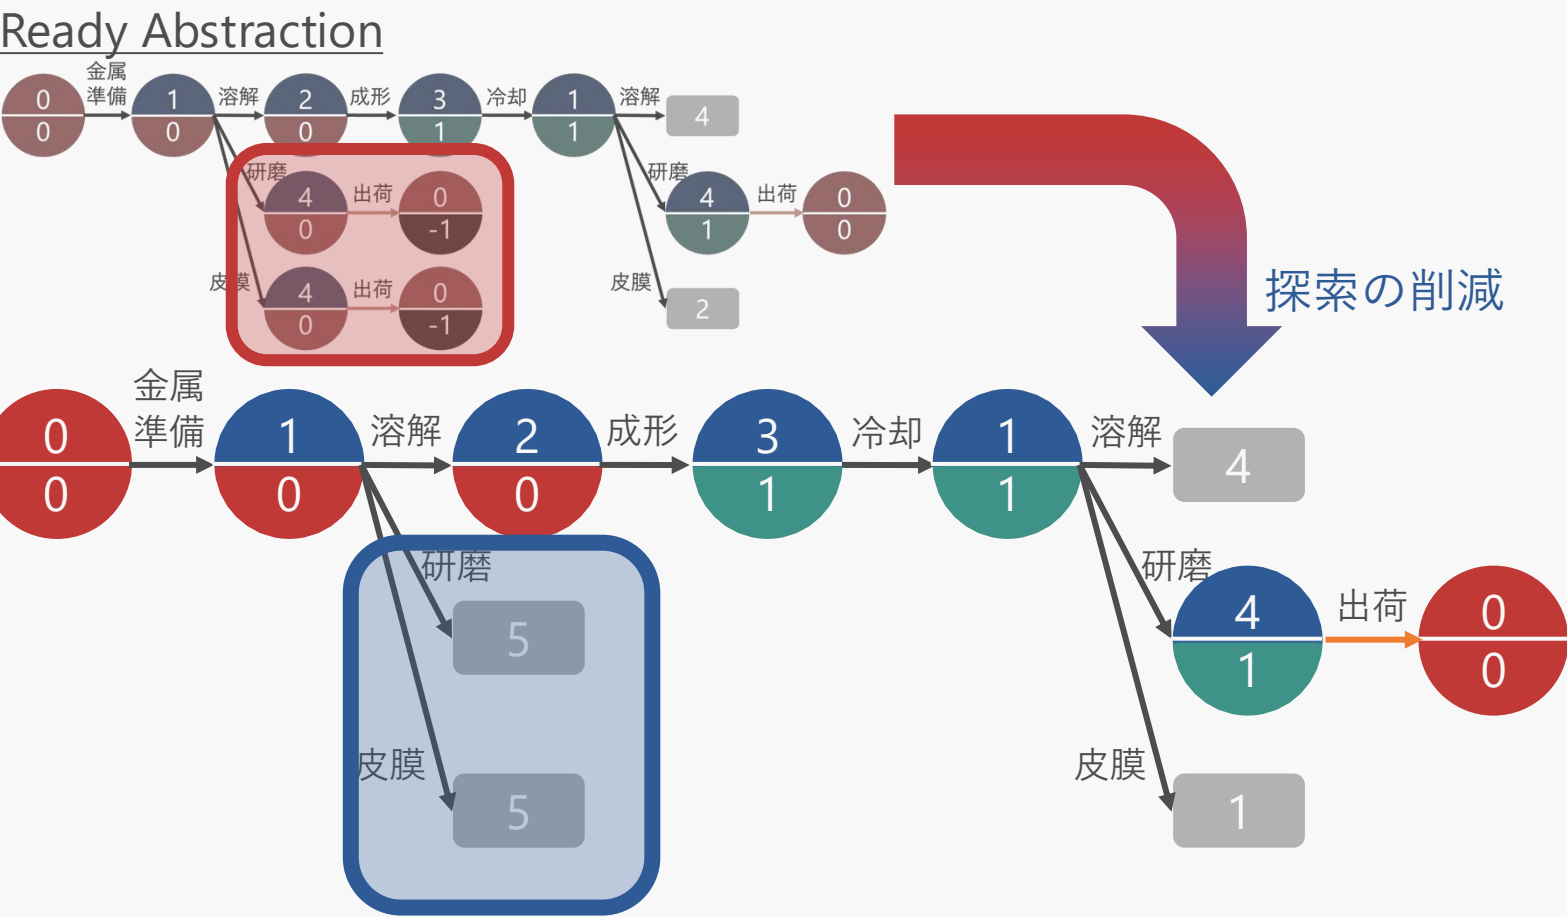
Landmark Ready Abstraction (LRA) による探索



Landmark Ready Abstraction (LRA) による探索



Landmark Ready Abstraction (LRA) による削減



リサーチクエスチョン

1. 探索効率の改善

PMAの導入により探索状態数を削減できるか

2. 探索コストの削減

メモリ使用量および合成時間を削減できるか

3. 規模拡大に対する耐性

大規模な問題においても有効性を維持できるか

実験設定

- 計算機環境：Intel Core Ultra 9 (128GB RAM)
- 条件：最大ヒープサイズ80GB・制限時間12時間
- 比較手法：RA, SRA, LRA
- **ベンチマーク：構造的特性の異なる5つの主要なベンチマーク**
 - Cat and Mouse (CM)¹：動的障害物（ネコ）を回避する経路計画
 - Dining Philosophers (DP)¹：共有リソースの排他制御とデッドロック回避
 - Drone Coordination (DC)²：複数ドローンの位置同期とバッテリー制御
 - Travel Agency (TA)¹：複数サービスの整合性を保つトランザクション制御
 - Kiva System (KS)³：物流倉庫における搬送ロボット群の衝突回避

1. Daniel Ciolek, Víctor Braberman, Nicolás D'Ippolito, Sebastián Sardiña, and Sebastián Uchitel. Compositional supervisory control via reactive synthesis and automated planning. *IEEE Transactions on Automatic Control*, Vol. 65, No. 8, pp. 3502–3516, 2020.

2. Yuki Arioka, Takuto Yamauchi, and Kenji Tei. Pre-controller synthesis for runtime controller synthesis. In *2023 IEEE 13th International Conference on Control System, Computing and Engineering (ICCSCE)*, pp. 161–166, 2023.

3. John J. Enright and Peter R. Wurman. Optimization and coordinated autonomy in mobile fulfillment systems. In *Proceedings of the 9th AAI Conference on Automated Action Planning for Autonomous Mobile Robots, AAAIWS'11-09*, pp. 33–38. AAAI Press, 2011.

実験結果の分類

PMAの密度と有効性に基づいて2つの傾向に分類

高PMA密度群

構造的なボトルネック（PMA）が多数存在するシナリオ

シナリオ	サイズ	$ A $	$ A^{PP} $	$ A^{SP} $	ρ [%]
CM	(2, 3)	31	8	0	25.8
	(2, 5)	47	12	0	25.5
	(3, 3)	45	11	0	24.4
	(3, 4)	57	14	0	24.6
	(4, 2)	43	10	0	23.2
DP	(3, 3)	22	15	0	68.1
	(4, 4)	29	20	0	69.0
	(4, 5)	29	20	0	69.0
	(5, 5)	36	25	0	69.4
DC	(2, 2)	38	2	9	29.0
	(3, 3)	68	3	14	25.0

履歴依存群

構造的制約よりも、過去の成功履歴が探索の指針となるシナリオ

シナリオ	サイズ	$ A $	$ A^{PP} $	$ A^{SP} $	ρ [%]
TA	(3, 3)	48	1	0	2.1
	(4, 4)	67	1	0	1.5
	(4, 5)	71	1	0	1.4
	(5, 5)	88	1	0	1.1
KS	2	53	1	5	11.3
	3	75	1	5	8.0

$|A|$ ：総アクション数 $|A^{PP}|$ ：PPMA数 $|A^{SP}|$ ：SPMA数
 ρ ：総アクション数に対する全PMA数の占有率

実験結果 1：高PMA密度群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			SRA			LRA		
		S	M [MiB]	T [ms]	S	M [MiB]	T [ms]	S	M [MiB]	T [ms]
CM	(2, 3)	2,113	639.65	1,568	1,440	452.01	594	460	115,97	211
	(2, 5)	11,284	759.39	116,454	11,896	927.87	164,845	6,571	931,73	19,285
	(3, 3)	36,083	1105.92	1,050,811	38,552	1341.44	1,668,333	4,729	960,61	33,728
	(3, 4)	-	-	T.O.	-	-	T.O.	10,309	738,85	207,353
	(4, 2)	59,362	1740.80	1,828,240	19,248	1792.00	609,075	13,901	1095.68	576,107
DP	(3, 3)	336	98.79	78	1,912	546.85	685	164	66.79	46
	(4, 4)	1,530	683.47	1,606	6,014	1,064.96	9,170	516	85.28	194
	(4, 5)	1,876	690.87	2,490	44,687	1,443.84	1,234,959	601	98.89	202
	(5, 5)	18,651	1,085.44	829,989	86,627	3,102.72	4,362,290	1,775	690.99	2,162
DC	(2, 2)	1,166	628.36	1,162	386	100.35	160	293	116.25	160
	(3, 3)	159,768	4,751.36	32,991,134	9,181	740.04	120,566	8,461	906.45	92,500

実験結果 1：高PMA密度群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			SRA			LRA		
		S	M [MiB]	T [ms]	S	M [MiB]	T [ms]	S	M [MiB]	T [ms]
CM	(2, 3)	2,113	639.65	1,568	1,440	527.87	594	460	115.97	211
	(2, 5)	11,284	759.39	116,454	11,896	927.87	164,845	6,571	931.73	19,285
	(3, 3)	36,083	1105.92	1,050,811	38,552	1341.4	134,140	4,729	960.61	33,728
	(3, 4)	-	-	T.O.	-	-	T.O.	10,309	738.85	207,353
	(4, 2)	59,362	1740.80	1,828,240	19,248	1792.00	609,075	13,901	1095.68	576,107
DP	(3, 3)	336	98.79	78	1,912	546.85	685	164	66.79	46
	(4, 4)	1,530	683.47	1,606	6,014	1,064.96	9,170	516	85.28	194
	(4, 5)	1,876	690.87	2,490	44,687	1,443.84	1,234,959	601	98.89	202
	(5, 5)	18,651	1,085.44	829,989	86,627	3,102.72	4,362,290	1,775	690.99	2,162
DC	(2, 2)	1,166	628.36	1,162	386	100.35	160	293	116.25	160
	(3, 3)	159,768	4,751.36	32,991,134	9,181	740.04	120,566	8,461	906.45	92,500

平均0.27倍

平均0.49倍

平均0.16倍

実験結果 1：高PMA密度群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			SRA			LRA		
		S	M [MiB]	T [ms]	S	M [MiB]	T [ms]	S	M [MiB]	T [ms]
CM	(2, 3)	2,113	639.65	1,560	460	115.97	211	460	115.97	211
	(2, 5)	11,284	759.39	116,450	6,571	931.73	19,285	6,571	931.73	19,285
	(3, 3)	36,083	1105.92	1,050,811	4,729	960.61	33,728	4,729	960.61	33,728
	(3, 4)	-	-	T.O.	-	T.O.	10,309	738.85	207,353	207,353
	(4, 2)	59,362	1740.80	1,828,240	13,901	1095.68	576,107	13,901	1095.68	576,107
DP	(3, 3)	336	98.79	78	1,912	546.85	685	164	66.79	46
	(4, 4)	1,530	683.47	1,606	1,064.96	9,170	516	85.28	194	194
	(4, 5)	1,876	690.87	2,490	1,443.84	1,234,959	601	98.89	202	202
	(5, 5)	18,651	1,085.44	829,989	86,627	3,102.72	4,362,290	1,775	690.99	2,162
DC	(2, 2)	1,166	628.36	1,162	386	100.35	160	293	116.25	160
	(3, 3)	159,768	4,751.36	32,991,134	9,181	740.04	120,566	8,461	906.45	92,500

問題が複雑になるほどPMAによる
誘導効果が高まる

約2倍

約10倍

実験結果 1：高PMA密度群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			CPA			LRA		
		S	M [MiB]	T				S	M [MiB]	T [ms]
CM	(2, 3)	2,113	639.65		従来解けなかった規模の問題が 解決可能			460	115,97	211
	(2, 5)	11,284	759.39	1				6,571	931,73	19,285
	(3, 3)	36,083	1105.92	1,050,811				4,729	960,61	33,728
	(3, 4)	-	-	T.O.	-	-	T.O.	10,309	738,85	207,353
	(4, 2)	59,362	1740.80	1,828,240	19,248	1792.00	609,075	13,901	1095.68	576,107
DP	(3, 3)	336	98.79	78	1,912	546.85	685	164	66.79	46
	(4, 4)	1,530	683.47	1,606	6,014	1,064.96	9,170	516	85.28	194
	(4, 5)	1,876	690.87	2,490	44,687	1,443.84	1,234,959	601	98.89	202
	(5, 5)	18,651	1,085.44	829,989	86,627	3,102.72	4,362,290	1,775	690.99	2,162
DC	(2, 2)	1,166	628.36	1,162	386	100.35	160	293	116.25	160
	(3, 3)	159,768	4,751.36	32,991,134	9,181	740.04	120,566	8,461	906.45	92,500

実験結果 2：履歴依存群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			SRA			LRA		
		S	M [MiB]	T [ms]	S	M [MiB]	T [ms]	S	M [MiB]	T [ms]
TA	(3, 3)	472	115.16	266	446	115.15	162	446	115.15	169
	(4, 4)	2,727	851.46	5,058	2,496	851.41	4,337	2,496	851.46	4,403
	(4, 5)	2,751	867.44	5,269	2,549	851.46	4,772	2,549	851.43	4,775
	(5, 5)	15,953	971.02	236,716	14,538	943.48	303,399	14,538	923.56	308,801
KS	2	376	638.74	1,387	2,408	702.80	1,018	995	144,547	575
	3	6,846	745.49	28,174	189,008	2,222.08	4,458,564	144,547	2,017.28	437,201

実験結果 2：履歴依存群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			SRA			LRA		
		S	M [MiB]	T [ms]	S	M [MiB]	T [ms]	S	M [MiB]	T [ms]
TA	(3, 3)	472	115.16	266	446	115.15	162	446	115.15	169
	(4, 4)	2,727	851.46	5,058	2,496	851.46	4,337	2,496	851.46	4,403
	(4, 5)	2,751	867.44	5,269	2,549	851.46	4,775	2,549	851.43	4,775
	(5, 5)	15,953	971.02	236,716	14,538	943.48	308,801	14,538	923.56	308,801
KS	2	376	638.74	1,387	2,408	702.80	1,018	995	144,547	575
	3	6,846	745.49	28,174	189,008	2,222.08	4,458,564	144,547	2,017.28	437,201

平均4.58倍

平均1.25倍

平均3.27倍

実験結果 2：履歴依存群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			SRA			LRA		
		S	M [MiB]	T [ms]				S	M [MiB]	T [ms]
TA	(3, 3)	472	115.16	266	探索履歴を考慮するRAの方が有効			446	115.15	169
	(4, 4)	2,727	851.46	5,058				2,496	851.46	4,403
	(4, 5)	2,751	867.44	5,269				2,549	851.43	4,775
	(5, 5)	15,953	971.02	236,716	1	3.48	303,399	14,538	923.56	308,801
KS	2	376	638.74	1,387	約1/20倍			995	144,547	575
	3	6,846	745.49	28,174	189,008	2,222.08	4,458,564	144,547	2,017.28	437,201

リサーチクエストションへの回答

1. 探索効率の改善

高PMA密度群：PMA誘導が機能し、大幅な削減に成功

履歴依存群：LRAは構造的制約が緩く、RAの方が有効

2. 探索コストの削減

高PMA密度群：探索空間の縮小により、メモリ・時間共に減少

履歴依存群：探索状態数の増加に伴い、RAよりもコストが増加

3. 規模拡大に対する耐性

高PMA密度群：RAがタイムアウトする問題でも安定

履歴依存群：探索履歴が有効な場合、RAの方が高い耐性

➡ 提案手法は構造的なボトルネックを持つ問題に対して特異的に有効

Landmark Ready Abstractionが有効な場面

実験の結果より、全アクションに対するPMAの占有率 ρ が、最適な手法を選択する指標となり得ることが示唆された

- ρ が20%以上の場合

システム内に構造的なボトルネックが多く、LRAが支配的な性能を示した
この場合はLRAの適用が有効であると考えられる

- ρ が20%未満の場合

構造的な制約が緩いため、探索履歴を利用するRAが有効に機能する傾向が見られた

➡事前の静的解析により ρ を算出し、システム特性に応じて適切なアルゴリズムを選択する運用が有効であると推察される

まとめ

- 目的** : DCSにおけるヒューリスティックの改善
- 課題** : 既存手法（RA）は局所最適を優先し、同期構造によるボトルネックを無視する
- 提案** : 目標到達に必須なPMAを中間目標とする手法LRAの提案
- 結果** : 指標 ρ を導入し、 $\rho \geq 0.2$ の環境下での有効性を実証
- 将来展望** : 探索履歴（RA）と中間目標（LRA）の双方を統合したヒューリスティックの開発

Directed Controller Synthesisのアルゴリズム

アルゴリズム 1 On-The-Fly 探索による Directed Controller Synthesis

入力： 全ての LTS の組 $E = (E_1, \dots, E_n)$, ヒューリスティック関数 H

出力： Directed Controller C または 合成不可能

1: **function** DIRECTEDCONTROLLERSYNTHESIS(E, H)

2: $ES \leftarrow$ 初期状態 s_0 のみを持つ部分探索グラフ

3: $Goals \leftarrow \emptyset, Errors \leftarrow \emptyset, None \leftarrow \{s_0\}$

4: ▷ 探索ループ：初期状態が未分類状態でなくなるまで ◁

5: **while** $s_0 \notin (Goals \cup Errors)$ **do**

6: $(s, a, s') \leftarrow$ EXPANDNEXT(ES, H) ▷ ヒューリスティックによる次遷移の選択

7: $ES \leftarrow ES \cup \{(s, a, s')\}$ ▷ 探索グラフの更新

8: **if** $s' \in Errors$ **then**

9: $Errors \leftarrow Errors \cup \{s'\}$

10: PROPAGATEERROR(s') ▷ 敗北状態の伝播

11: **else if** $s' \in Goals$ **then**

12: $Goals \leftarrow Goals \cup \{s'\}$

13: PROPAGATEGOAL(s') ▷ 勝利状態の伝播

14: **else if** s' が新しいループを形成する **then**

15: $Loop \leftarrow$ GETLOOP(s, s')

16: **if** $Loop$ が勝利条件を満たす **then**

17: $newGoals \leftarrow$ FINDNEWGOALS($Loop$)

18: $Goals \leftarrow Goals \cup newGoals$

19: PROPAGATEGOAL($newGoals$)

20: **else**

21: $newErrors \leftarrow$ FINDNEWERRORS($Loop$)

22: $Errors \leftarrow Errors \cup newErrors$

23: PROPAGATEERROR($newErrors$)

24: **if** $s_0 \in Goals$ **then**

25: $C \leftarrow$ EXTRACTCONTROLLER($ES, Goals$)

26: **return** C

27: **else**

28: **return** 合成不可能

Ready Abstractionによる距離推定のアルゴリズム

アルゴリズム 3 Ready Abstraction における距離推定関数

入力: 現在の状態 $\mathbf{s} = (s_{E_1}, \dots, s_{E_n})$,

評価対象のアクション \hat{a} ,

距離を推定する対象の状態 $s_{E_i}^*$

出力: 推定距離 $d \in \mathbb{N} \cup \{\infty\}$

```

1: function ESTIMATEDISTTOSTATE( $\mathbf{s}, \hat{a}, s_{E_i}^*$ )
2:   if  $\hat{a} \in A_{E_i}$  then                                     ▷  $\hat{a}$  が LTS  $E_i$  に存在している場合
3:      $s'_{E_i} \leftarrow s'$  where  $(s_{E_i}, \hat{a}, s') \in \Delta_{E_i}$       ▷  $\hat{a}$  を発火した後の状態
4:     if  $s'_{E_i} = s_{E_i}^*$  then                                   ▷ 対象の状態に到達する場合
5:       return 1
6:     else if  $s'_{E_i} \in S_{E_i}^I$  then                             ▷ 違反状態に到達する場合
7:       return  $\infty$                                              ▷ 距離を無限と推定し, Marked 状態に到達不可能であることを表す
8:     else if  $s'_{E_i} \neq s_{E_i}$  then                             ▷ 他の状態に遷移する場合
9:       return CALCULATEDIST( $s'_{E_i}, s_{E_i}^*$ ) + 1

10:  ▷ 各 LTS 上で, 現在の状態から発火可能なアクション (Ready アクション) を収集
11:   $A^R \leftarrow \bigcup_{i=1}^n \{a \mid \exists s, (s_{E_i}, a, s) \in \Delta_{E_i}, s \neq s_{E_i}, s \notin S_{E_i}^I\}$ 

12:  ▷ 候補アクション  $\hat{a}$  から構造的に到達可能なアクション集合  $A^*$  を構築
13:   $A^* \leftarrow \emptyset$ 
14:  for  $i = 1, \dots, n$  do
15:     $s'_{E_i} \leftarrow s'$  where  $(s_{E_i}, \hat{a}, s') \in \Delta_{E_i}$ 
16:    if  $s'_{E_i} \neq \perp \wedge s'_{E_i} \notin S_{E_i}^I$  then
17:       $A^* \leftarrow A^* \cup \{a^* \in A^R \mid T_{s'_{E_i} \rightarrow \{a^*\}} \neq \emptyset\}$ 

18:  ▷ Gap を加味した最短経路探索
19:   $d \leftarrow \min_{a^* \in A^*} \{\text{CALCULATEGAP}(\mathbf{s}, \hat{a}, a^*) + \text{ESTIMATEDISTTOSTATE}(\mathbf{s}, a^*, s_{E_i}^*)\}$ 
20:  ▷ この再帰的な最小値問題は, 実装上はダイクストラ法により効率的に解かれる
21:  return  $d$ 

```

実験結果 1：高PMA密度群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合成時間 [ms]

シナリオ	サイズ	RA			SRA			LRA		
		S	M [MiB]	T [ms]	S	M [MiB]	T [ms]	S	M [MiB]	T [ms]
CM	(2, 3)	2,113	639.65	1,568	1,440	452.01	594	460	115,97	211
	(2, 5)	11,284	759.39	116,454	11,896	927.87	164,845	6,571	931,73	19,285
	(3, 3)	36,083	1105.92	1,050,811	38,552	1341.44	1,668,333	4,729	960,61	33,728
	(3, 4)	-	-	T.O.	-	-	T.O.	10,309	738,85	207,353
	(4, 2)	59,362	1				609,075	13,901	1095.68	576,107
DP	(3, 3)	336					685	164	66.79	46
	(4, 4)	1,530					9,170	516	85.28	194
	(4, 5)	1,876	650.87	7,450	44,687	1,445.84	1,234,959	601	98.89	202
	(5, 5)	18,651	1,085		86,627	3,102.72	4,362,290	1,775	690.99	2,162
DC	(2, 2)	1,164	628		386	100.35	160	293	116.25	160
	(3, 3)	159,768	4,751.36	32,991,134	9,181	740.04	120,566	8,461	906.45	92,500

RAが探索履歴を優先しすぎており
性能が不安定

大幅に悪化

実験結果 2：履歴依存群

|S|：探索状態数
M：最大ヒープ使用量 [MiB]
T：合計時間 [ms]

シナリオ	サイズ	RA			TAにおいては、 RAは探索履歴の考慮により、 DCSのアルゴリズムが得意な探索を実行					
		S	M [MiB]	T [ms]	S					T [ms]
TA	(3, 3)	472	115.16	266	446					169
	(4, 4)	2,727	851.46	5,058		851.41	4,337	2,496	851.46	4,403
	(4, 5)	2,751	867.44	5,269	減少	851.46	4,772	2,549	851.43	4,775
	(5, 5)	15,953	971.02	236,716		14,538	943.48	303,399	14,538	923.56
KS	2	376	638.74	1,387		2,408	702.80	995	144,547	575
	3	6,846	745.49	28,174		189,008	2,222.08	増加	144,547	2,017.28

TAにおいては、
RAは探索履歴の考慮により、
DCSのアルゴリズムが得意な探索を実行

減少

増加

その他の実験結果

表 5.1 Air Traffic シナリオの実験結果

(N, K)	手法	$ S $	M [MiB]	T [ms]	T_{eval} [ms]
(4, 5)	BFS	6,025 (12.8)	995.75 (8.5)	21,311 (147.0)	-
	RA	485 (1.0)	132.56 (1.1)	516 (3.6)	382 (3.3)
	SRA	472 (1.0)	116.63 (1.0)	136 (0.9)	115 (1.0)
	LRA	472 (1.0)	116.67 (1.0)	145 (1.0)	117 (1.0)
(5, 5)	BFS	41,833 (13.6)	1,474.56 (2.1)	2,194,145 (2,119.9)	-
	RA	2,743 (0.9)	693.01 (1.0)	6,792 (6.6)	3,022 (4.5)
	SRA	3,078 (1.0)	693.05 (1.0)	1,007 (1.0)	624 (0.9)
	LRA	3,078 (1.0)	693.01 (1.0)	1,035 (1.0)	665 (1.0)
(5, 10)	BFS	-	-	T.O.	-
	RA	2,756 (2.4)	711.16 (1.0)	15,885 (15.3)	11,931 (13.3)
	SRA	1,134 (1.0)	695.20 (1.0)	1,030 (1.0)	877 (1.0)
	LRA	1,134 (1.0)	695.23 (1.0)	1,039 (1.0)	895 (1.0)

表 5.2 Air Traffic シナリオにおける PMA の構成

(N, K)	$ A $	$ A^{PP} $	$ A^{SP} $	ρ [%]
(4, 5)	37	0	0	0.0
(5, 5)	46	0	0	0.0
(5, 10)	71	0	0	0.0

表 5.3 Bidding Workflow シナリオの実験結果

(N, K)	手法	$ S $	M [MiB]	T [ms]	T_{eval} [ms]
(4, 4)	BFS	7,538 (123.6)	1,095.68 (31.5)	125,731 (6,617.4)	-
	RA	61 (1.0)	34.76 (1.0)	32 (1.7)	16 (2.0)
	SRA	61 (1.0)	34.82 (1.0)	17 (0.9)	9 (1.1)
	LRA	61 (1.0)	34.76 (1.0)	19 (1.0)	8 (1.0)
(4, 5)	BFS	15,135 (201.8)	1,259.52 (36.2)	863,799 (35,991.6)	-
	RA	75 (1.0)	34.79 (1.0)	32 (1.3)	22 (1.5)
	SRA	75 (1.0)	34.78 (1.0)	20 (0.8)	8 (0.5)
	LRA	75 (1.0)	34.84 (1.0)	24 (1.0)	15 (1.0)
(5, 4)	BFS	62,042 (805.7)	2,959.36 (85.0)	31,230,321 (1,419,560.0)	-
	RA	77 (1.0)	34.86 (1.0)	33 (1.5)	18 (1.4)
	SRA	77 (1.0)	34.81 (1.0)	17 (0.8)	9 (0.7)
	LRA	77 (1.0)	34.80 (1.0)	22 (1.0)	13 (1.0)
(5, 5)	BFS	-	-	T.O.	-
	RA	95 (1.0)	50.87 (1.5)	40 (1.5)	25 (1.8)
	SRA	95 (1.0)	34.83 (1.0)	24 (0.9)	9 (0.6)
	LRA	95 (1.0)	34.87 (1.0)	26 (1.0)	14 (1.0)

表 5.4 Bidding Workflow シナリオにおける PMA の構成

(N, K)	$ A $	$ A^{PP} $	$ A^{SP} $	ρ [%]
(4, 4)	27	1	0	3.7
(4, 5)	31	1	0	3.2
(5, 4)	33	1	0	3.0
(5, 5)	38	1	0	2.6

表 5.11 Transfer Line シナリオの実験結果

(N, K)	手法	$ S $	M [MiB]	T [ms]	T_{eval} [ms]
(10, 10)	BFS	-	-	T.O.	-
	RA	68 (1.0)	256.14 (1.9)	567 (3.7)	438 (36.5)
	SRA	68 (1.0)	118.05 (0.9)	95 (0.6)	8 (0.7)
	LRA	68 (1.0)	134.04 (1.0)	153 (1.0)	12 (1.0)
(15, 15)	BFS	-	-	T.O.	-
	RA	98 (1.0)	851.97 (1.4)	2,474 (6.5)	2,063 (62.5)
	SRA	98 (1.0)	585.85 (1.0)	358 (0.9)	18 (0.5)
	LRA	98 (1.0)	601.75 (1.0)	378 (1.0)	33 (1.0)
(20, 20)	BFS	-	-	T.O.	-
	RA	128 (1.0)	2,099.20 (2.9)	8,252 (7.4)	7,316 (124.0)
	SRA	128 (1.0)	702.81 (1.0)	1,005 (0.9)	41 (0.7)
	LRA	128 (1.0)	721.44 (1.0)	1,121 (1.0)	59 (1.0)

表 5.12 Transfer Line シナリオにおける PMA の構成

(N, K)	$ A $	$ A^{PP} $	$ A^{SP} $	ρ [%]
(10, 10)	244	1	0	0.4
(15, 15)	514	1	0	0.2
(20, 20)	844	1	0	0.1